

BOK 이슈노트

디지털 신기술을 이용한 실시간 당분기 경제전망 (GDP nowcasting) 시스템 개발



이현창

한국은행 디지털혁신실
디지털신기술반 반장
Tel. 02-759-4869
hyunchang.yi@bok.or.kr

최동규

한국은행 디지털혁신실
디지털신기술반 과장
Tel. 02-759-4746
cdk@bok.or.kr

김용건

한국은행 경제연구원
거시경제연구실 부연구위원
Tel. 02-759-5349
ygkim@bok.or.kr

허정

한국은행 경제연구원
거시경제연구실 조사역
Tel. 02-759-4863
imjung@bok.or.kr

2022년 2월 3일

코로나19 팬데믹, 기후 변화 등으로 경제 불확실성이 높아지면서 경기상황을 적시에 판단할 수 있는 지표에 대한 관심이 높아지고 있다. 그러나, 전반적인 경기상황을 나타내는 GDP 성장률의 경우 공표 주기와 시차가 길어 현재 경기상황을 판단하는 지표로 활용하는 데 한계가 있다. 이에 본 연구는 매주 GDP 성장률 예측치를 업데이트하며 경기흐름을 파악하는 실시간 당분기 경제전망(GDP nowcasting) 시스템을 개발하였다. 동 시스템은 주요국 중앙은행의 GDP nowcasting 전망모형으로 이용되는 동적요인모형(DFM, Dynamic Factor Model)과 최근 빠르게 발전한 기계학습(ML, Machine Learning) 알고리즘 가운데 시계열 데이터에 특화된 LSTM(Long Short-Term Memory)을 상호보완적으로 적용하여 예측력을 제고하였다.

2017년 1분기부터 2021년 3분기까지 기간에 대해 실시간 GDP nowcasting 시스템의 예측력을 평가한 결과, DFM과 LSTM 전망모형 모두 실제 경기흐름을 적절히 포착하는 것으로 나타났다. 동 시스템은 2020년 1분기와 2분기의 급격한 GDP 성장률 하락, 2020년 3분기의 GDP 성장률 반등 움직임을 조기에 포착한 것으로 나타났다. 특히, LSTM 전망모형은 코로나19 유행과 같이 경제 불확실성이 확대된 상황에서 상대적으로 높은 예측력을 보였다. 이는 인공지능망 구조에 기반한 LSTM 알고리즘이 변수 간 비선형, 상호의존적 관계를 포착하는데 효과적이기 때문인 것으로 판단된다. 지속적인 대체데이터 발굴, 전망모형 개선 등의 노력이 이어진다면, 광범위한 데이터 기반(evidence-based) 경제전망 체계와 경제전망 담당자의 정성적 판단을 유기적으로 활용하여 보다 신속하고 효율적인 정책수행이 가능할 것으로 기대된다.

최근 주요국 중앙은행, 국제기구 등은 기계학습과 같은 분석기법을 빅데이터에 적용하여 경제전망의 적시성과 정확도를 높이기 위해 노력하고 있다. 본 연구는 기계학습 알고리즘뿐만 아니라 기존 빅데이터 기반 경제전망 연구성과가 축적된 계량경제모형을 상호보완적으로 활용하여 예측력 높은 GDP nowcasting 시스템을 개발하였다. 이러한 성과는 점차 중요성이 높아지고 있는 다양한 빅데이터 및 기계학습 알고리즘을 효과적으로 활용하는 방안을 제시한다는 점에서도 의미가 크다고 할 수 있다.

- 본 자료의 내용은 한국은행의 공식견해가 아니라 집필자 개인의 견해라는 점을 밝힙니다.
따라서 본 자료의 내용을 보도하거나 인용할 경우에는 집필자명을 반드시 명시하여 주시기 바랍니다.
- 본고의 작성 과정에서 큰 도움을 주신 정성호 디지털혁신실장, 박양수 경제연구원장, 나승호 거시경제연구실장님과 행내 세미나에 참석하여 귀중한 의견을 주신 권효성 의제연구반장과 지정구 총복기획조사팀장을 비롯한 세미나 참석자분들께 감사드립니다. 그리고, 원고 심사 과정에서 유익한 의견을 주신 서범석 통계기획팀 과장, 황설웅 금융통화연구실 부연구위원께도 감사드립니다.



한국은행

I. 머리말

코로나19 팬데믹, 기후 변화 등으로 경제 불확실성이 높아지면서 경기상황을 적시에 판단할 수 있는 지표에 대한 관심이 높아지고 있다. 그러나, 종합적인 경기상황을 나타내는 GDP 성장률의 경우 공표 주기와 시차가 길어 현재 경기상황을 판단하는 지표로 활용하는 데 한계가 있다. 우리나라 GDP 성장률의 경우 분기 주기로 작성되며 분기 종료 이후 속보치 공표까지 약 한 달가량, 잠정치 공표까지는 약 두 달가량의 시차가 있다.

이에 따라 주요국 중앙은행은 현재 경기상황을 판단하기 위해 당분기 GDP 성장률 전망(GDP nowcasting)을 이용한다. 전반적인 경기상황과 상관관계가 높고 상대적으로 공표 주기가 짧은 산업생산지수, 수출입, 물가상승률 등 월별 경제지표를 이용하여 당분기 GDP 성장률을 예측하고, 또한 새로운 경제지표가 입수될 때마다 예측치를 업데이트함으로써 현재 경기흐름을 파악할 수 있다. 이러한 GDP nowcasting 프로세스는 주관적 판단을 배제하고 계량경제모형에 기반하여 현재 경기흐름에 대한 데이터 기반 판단지표를 제공하므로 경제전망 담당자 및 정책 의사결정자는 경기상황에 대한 정성적 평가와 함께 보완적으로 활용할 수 있다.

한편, 디지털 경제 가속화로 다양한 비정형·고빈도 데이터의 생산·공유가 용이해지는 가운데 여러 분야에서 기계학습(ML, Machine Learning) 알고리즘을 예측, 분류와 같은 문제에 활용하는 사례가 늘고 있다. 이를 반영하여 학계, 국제기구, 각국 중앙은행 등에서는 기존 경제통계뿐 아니라 텍스트 데이터, 전력사

용량, 온라인 쇼핑 등 다양한 대체데이터에 기계학습 알고리즘을 적용하여 GDP 성장률, 물가, 환율과 같은 경제변수 전망의 예측력을 높이는 시도가 활발하게 이루어지고 있다.

본 연구는 주요국 중앙은행의 GDP nowcasting 활용 사례를 참고하여 월별 경제지표와 계량경제모형을 이용하여 기본적인 GDP nowcasting 시스템의 구조를 설정한 다음, 기계학습 알고리즘을 적용하여 예측력을 개선하였다.

본고의 구성은 다음과 같다. 먼저 II절에서 GDP nowcasting 전망모형 관련 주요 이슈를 정리하고 본 연구의 개발 방향을 설명한다. III절은 동적요인모형(DFM, Dynamic Factor Model) 기반 GDP nowcasting 전망모형의 구조와 실시간 경제전망 프로세스를 설명한다. IV절은 기계학습 알고리즘을 소개하고 동적요인모형과 기계학습 알고리즘을 상호보완적으로 활용한 GDP nowcasting 시스템의 구조와 전망결과를 설명한다. 마지막으로 V절은 본고 내용을 요약하고 시사점을 정리한다.

II. 주요 이슈 및 개발 방향

1. 주요 이슈


고빈도 데이터를 효율적으로 활용하여 GDP nowcasting 전망모형의 예측력을 높이기 위해서는 크게 세 가지 문제를 해결해야 한다.

첫 번째는 입력 변수의 주기 불일치(frequency mismatch)와 결측치(missing data) 문제이다. 주기 불일치는 분기 GDP

성장률을 예측하기 위해 월별 경제변수를 이 용함에 따라 변수 간의 주기가 서로 다른 것 을 의미한다. 경제이론에 근거한 대부분 계량 경제모형은 경제변수가 같은 주기를 갖는 것 으로 가정하므로, 주기가 일치하지 않는 경우 일반적인 계량분석을 적용하기 어렵다. 또한, GDP 성장률과 같은 저빈도 경제변수를 예측 하기 위해 고빈도(월, 주 등) 경제변수의 시차 변수를 포함할 경우 입력변수의 수가 크게 증 가하여 모형 추정이 어려워진다는 문제가 있 다. 변수 주기를 일치시키기 위해 분기중 평균 과 같은 대푯값을 이용하여 고빈도 변수의 주 기를 저빈도 변수의 주기와 일치시키는 방법 (temporal aggregation)을 고려할 수 있으 나, 이 방법은 고빈도 변수의 정보가 손실된다 는 한계가 있다.

결측치 문제는 동일 주기의 정보변수라 할 지라도 공표 시차가 서로 다르기 때문에 매 시 점 일부 변수는 마지막 월까지 모든 값이 채워 져있으나 다른 변수는 최근 값이 공표되지 않 아 입력변수 데이터셋의 끝단이 들쭉날쭉한 (ragged-edge)한 것을 뜻한다(〈그림 1〉 참 고). GDP nowcasting은 당분기 경기상황 에 대한 정보를 갖고 있는 최근 경제지표를 이 용하여 예측력을 높여야 하는데, 일반적인 계 량경제모형은 특정 시점에 단 하나의 변수라도 결측치가 있는 경우 해당 시점의 데이터를 모 두 사용할 수 없게 된다. 따라서, 당분기 경기 상황을 나타내는 경제지표를 모두 활용하기 위 해서는 결측치 문제를 효율적으로 해결하는 방 법을 강구해야 한다.

〈그림 1〉 ragged-edge 문제(2021년 4월 예시)



두 번째는 많은 수의 경제지표를 설명변수 로 포함하면서 발생할 수 있는 차원의 저주 (curse of dimensionality)¹⁾이다. 전반적 인 경기상황을 나타내는 GDP 성장률을 전망 하기 위해서는 소비 · 투자 · 수출입, 제조업 · 서비스업, 경제주체 심리지수 등 다양한 경제 지표로부터 정보를 추출해야 한다. 이때 여러 경제지표 간의 상호관계를 고려할 경우 파라 미터(parameter)의 수가 크게 증가하여 파라 미터 추정의 안정성이 저하될 수 있다. 한편, 설명변수 간 상호관계를 고려하지 않는 간단 한 모형을 사용할 경우 모형 설정 오류(model misspecification)가 발생할 우려가 있다 (Bok et al., 2018).

세 번째는 실시간 데이터셋 구축이다. 국민 계정을 비롯한 많은 경제지표가 해당 기간이 끝 난 다음 공표되며, 이후 값이 수정(revision)

1) 계량모형에서 관측치의 크기에 비해 추정 대상 파라미터 수가 너무 많아 모형 추정이 어려워지거나 불가능해지는 것을 의미한다.

되는 경우도 많다. 따라서 과거 기간에 대해 전망모형의 예측력을 평가하기 위해서는 과거 각 전망시점별로 실제 입수가능한 데이터로 구성된 빈티지 데이터셋(vintage dataset)을 이용해야 한다. 대부분 관련 연구에서는 준(pseudo) 빈티지 데이터셋²⁾을 구축하여 전망모형 평가에 이용한다. 만약 각 경제지표에 데이터 입수 로그(입수 및 수정 시점, 시점별 관측치)가 있는 경우, 이를 이용하여 과거 각 시점별 빈티지 데이터셋을 구축할 수 있다.

2. 주요국 현황 및 선행 연구

GDP nowcasting에 쓰이는 계량 모형은 크게 교량방정식(BE, Bridge Equation), 혼합주기모형(MIDAS, Mixed Data Sampling) 등 단일 방정식 모형³⁾과 동적요인모형(DFM, Dynamic Factor Model), 벡터자기회귀모형(VAR, Vector Auto Regression) 등 다변수 동적 모형으로 분류된다. 각 모형은 다양한 방식으로 앞서 설명한 문제를 고려하여 당분기 GDP 성장률을 예측한다. 특히, DFM의 경우 정보 손실 없이 주기 불일치 및 결측치 문제를 해결하고, 많은 수의 경제지표를 입력변수로 활용할 수 있다는 장점이 있어 주요국 중앙은행에서 활용되는 사례가 늘고 있다.

뉴욕 및 애틀랜타 연준은 주기적으로 GDP

nowcasting 결과를 홈페이지에 공표하고 있으며,⁴⁾ 두 연준 모두 주관적 판단을 배제하고 모형에 의한 전망결과만을 공표하고 있다. 뉴욕 연준은 매주 금요일 당분기 GDP 성장률 예측을 공표하며, 애틀랜타 연준은 전망모형에 포함된 주요 경제지표(예: ISM제조업 지수 등)가 공표되는 시점마다 당분기 GDP 성장률 예측을 공표한다. 영란은행에서는 산업모형⁵⁾(industry model), MIDAS, DFM을 모두 이용하여 당분기 경제성장률을 전망하고, 통화위원회(MPC)가 이들 결과를 모두 고려하여 최종적으로 판단하는 방식으로 당분기 경제전망을 수행하고 있다. 이외에도 각국 중앙은행을 중심으로 당분기 경제전망 관련 연구가 활발하게 이루어지고 있다(아래 <표 1>).

<표 1> 각국 중앙은행의 GDP nowcasting 모형⁶⁾

국가	모형
인도	DFM
유로(ECB)	DFM, BVAR(Bayesian VAR)
덴마크	DFM
핀란드	BVAR
독일	DFM, BE, MIDAS
일본	BE, MIDAS, factor-MIDAS
캐나다	BE, MIDAS, DFM, BVAR
아일랜드	DFM
멕시코	BE, DFM

주: BE는 교량방정식, MIDAS는 혼합주기모형, DFM은 동적요인모형, VAR은 벡터자기회귀모형을 의미

자료: 각국 중앙은행

2) 각 경제지표의 공표 주기와 시차 정보를 이용하여 과거 특정 시점에 동 경제지표의 관측치가 입수되었는지 여부를 판단할 수 있다. 이러한 정보를 이용하여 각 전망시점별로 구축한 데이터셋을 준 빈티지 데이터셋이라고 한다. 다만, 준 빈티지 데이터셋은 GDP 성장률 속도치, 잠정치, 확정치와 같은 데이터 수정을 반영하지 않으므로 실제 빈티지 데이터셋과 차이가 있다.

3) 모형에 대한 상세한 설명은 "III. DFM 전망모형"의 "2. 기존모형 대비 장점"을 참고하라.

4) 뉴욕 연준은 코로나19 팬데믹 이후 전망 오차가 확대됨에 따라 2021년 2분기 이후 nowcasting 결과를 공개하지 않고 있다.

5) 영국 통계청에서 제공하는 산업 부문별 월별 지표를 이용하여 GDP 성장률 속도치 추정 방법과 유사하게 상향식(bottom-up)으로 GDP 성장률을 예측하는 기법이다(Anesti et al., 2017).

6) 각국 중앙은행에서 발표한 연구보고서(working paper)를 참고하였다. 인도는 Bhadury et al.(2020), 유로지역은 Banbura et al.(2014), Cimadomo et al.(2020), 덴마크는 Schmith and Grenestam(2021), 핀란드는 Itkonen and Juvonen(2017), 독일은 Eraslan and Schroder(2019), Kim(2019), Schumacher(2014), 일본은 Chikamatsu et al.(2018), 캐나다는 Chernis and Sekkel(2017, 2018), 아일랜드는 Liebermann(2014), 멕시코는 Galvez-Soriano(2018)의 연구를 참조하였다.

우리나라에서도 당분기 경제전망 관련 연구가 다수 있었으나, 대부분 교량방정식과 MIDAS를 중심으로 이루어졌으며, 주요국 중앙은행에서 주로 이용되는 DFM을 이용한 연구는 제한적이다.

이동수(2013)는 GDP 성장률의 자기회귀(AR, Auto-Regressive)모형에 외생변수로 월별 전산업생산지수를 포함한 ARX(외생변수가 포함된 AR모형)모형을 이용하였다. 이와 유사하게 김덕파 외(2020)는 정보변수별로 다수의 ARX모형을 추정한 다음 전망치를 결합하는 예측조합(forecast combination)을 이용하였다. 최병재·한진현(2014)은 교량방정식과 예측조합을 이용하여 단기 전망을 실시하였고, 이순웅·이은경·한진현(2017)은 교량방정식에 MIDAS와 기계학습 모형을 추가하여 1,000개 가량의 전망치를 생성한 다음 예측조합을 적용하였다. 황선웅·박문수(2012), 형남원·최경욱·최병재(2016), Kim and Swanson(2017)은 각각 MIDAS를 다양하게 변형한 모형을 이용하였다. 박강우·이중식(2009)은 two-step DFM을 적용하였으며, 김치호·김현정(2016)은 교량방정식과 주성분분석(PCA)을 이용한 DFM 전망에 예측조합을 적용하였다.

3. 개발 방향

본 연구는 전망 담당자가 실제 경제전망 프로세스에서 활용할 수 있는 예측력 높은 GDP nowcasting 시스템을 개발하고자 하였다.

이를 위해, 주요 선진국 중앙은행의 GDP nowcasting 전망모형 개발 및 운용 노하우를 활용하는 한편, 예측력 개선을 위해 변수 간 비선형, 상호의존적 관계를 포착하는데 용이한 기계학습(ML) 알고리즘을 적용한다. 보다 구체적으로 뉴욕 연준 등 주요국 중앙은행에서 개발·운영되며 현재 최고 수준(state-of-the-art)의 GDP nowcasting 전망모형으로 평가받는 DFM에 시계열 데이터에 특화된 ML 알고리즘을 적용하여 두 모형이 가진 장점을 극대화하는 것을 기본적인 시스템 개발 방향으로 정하였다.

DFM은 주기 불일치 및 결측치 문제 해결시 정보 손실을 최소화할 수 있고 많은 수의 경제지표를 활용할 수 있다는 점과 함께, 여러 경제변수의 구조적 관계를 고려할 수 있다는 장점이 있다. 동시에 DFM은 기본적으로 변수 간 선형 관계를 가정하므로 경제 불확실성이 큰 상황에서 예측력이 하락할 수 있다는 한계도 있다. 한편, ML 알고리즘은 변수 간 비선형, 상호의존적 관계를 포착하여 예측력을 높일 수 있다는 장점이 있으나, 이를 위해서는 입력변수가 목표변수와 안정적인(stationary) 관계를 가져야 하며, 많은 수의 파라미터로 구성된 ML 알고리즘을 학습하기 위해 상대적으로 큰 데이터셋을 확보할 필요가 있다. 이를 위해 본 연구는 DFM 전망모형에서 생성된 월별 GDP 성장률⁷⁾을 ML 알고리즘 학습에 이용하였다.

또한, 본 연구는 DFM 추정과 ML 알고리즘 학습, 전망모형의 정확한 예측력 평가를 위해 전망시점별 빈티지 데이터셋을 구축하였다.

7) DFM은 월별 공통요인과 개별요인의 선형결합으로 월별 GDP 성장률이 결정되는 것으로 가정하며, 분기 GDP 성장률은 월별 GDP 성장률의 선형결합으로 표현된다. 또한, 분기 GDP 성장률은 매분기 마지막월에 관측되는 것으로 가정한다. 이러한 관계를 이용하여, 3, 6, 9, 12월 분기 GDP 성장률과 매월 경제지표 관측치를 이용하여 GDP 성장률 결측치(1, 2, 4, 5, 7, 8, 10, 11월)를 추정할 수 있다. 또한, 3분기 GDP 성장률 전망시 DFM은 3분기까지 월별 경제지표 값을 예측하여 9월까지 결측치가 없는 입력변수 데이터셋을 생성한다. 보다 자세한 설명은 "III. DFM 전망모형"을 참고하라.

이를 위해 한국은행 조사연구플랫폼(BReiT)의 데이터 입수 로그를 이용하였다. 데이터 입수 로그는 각 경제지표의 최초 공표 일자와 값, 수정 일자와 값을 각각 포함하고 있어, 과거 시점에 실제 입수할 수 있었던 데이터셋을 구축하는데 활용할 수 있었다.⁸⁾

을 순서대로 적용하여 전망시점까지의 공통요인 값을 추정하고, DFM 전이식을 이용하여 전망시점 이후부터 당분기 마지막 월까지 공통요인 값을 예측한다. 당분기 GDP 성장률은 당분기 마지막 월까지 공통요인의 선형결합으로 계산된다.

2. 기존모형 대비 장점

III. DFM 전망모형

1. 개요

DFM은 관측된 변수를 관측되지 않는 공통요인(f_t)과 개별요인(ε_t)의 선형 결합으로 설명하며, 아래와 같은 상태공간모형⁹⁾(state-space model)으로 표현된다.

$$\begin{aligned} \text{[관측식]} \quad x_t &= Cf_t + \varepsilon_t \\ (\varepsilon_t \text{는 AR(1)과정을 따름}) \end{aligned}$$

$$\begin{aligned} \text{[전이식]} \quad f_t &= Af_{t-1} + u_t \\ (u_t \sim iid \ N[0, Q]) \end{aligned}$$

DFM을 추정하는 방법으로는 일반적으로 비모수, 베이지언, 최대우도추정법(MLE, Maximum Likelihood Estimation) 등이 있다. 본 연구에서는 결측치가 있는 경우에도 효율적인 파라미터 추정이 가능한 EM(Expectation Maximization) 알고리즘 기반 최대우도추정법을 적용하였다.

다음으로 DFM 추정결과를 이용하여 당분기 GDP 성장률(전기대비, 실질, 계절조정)을 예측한다. 먼저 DFM에 칼만 필터링과 스무딩

기존 GDP nowcasting 연구에서 널리 사용된 교량방정식은 월별 입력변수를 분기화하는 과정에서 정보 손실이 발생한다. 반면, 본 연구에서와 같이 월별 입력변수와 분기 GDP 성장률의 관계를 DFM으로 설정한 다음 EM 알고리즘 기반 최대우도추정법을 이용하여 DFM 파라미터를 추정할 경우 주기변환에 따른 정보 손실 없이 분기 GDP 성장률 전망모형을 추정할 수 있다.

MIDAS는 교량방정식과 달리 주기를 변환하지 않고 전망시점까지 입수된 월별 경제변수를 이용하여 전망모형을 구성한다. 이 경우 전망시점에 따라 전망에 활용되는 변수 구성이 바뀌게 된다. 이러한 방식은 현재 입수할 수 있는 모든 정보를 전망에 활용한다는 장점은 있으나, 새로 공표된 경제지표를 반영하여 GDP 성장률 예측치를 업데이트할 경우 그 변동내역을 일관되게 설명할 수 없다는 단점이 있다. 예를 들어, 지난 월 실업률 지표가 새로 공표되어 당분기 GDP 성장률 예측치가 상향조정되었다고 할 때, 동 변동이 새로 발표된 실업률 때문인지 이전과 다른 전망모형을 이용

8) 한국은행 조사연구플랫폼이 구축된 2019년 이전은 준(pseudo) 빈티지 데이터셋을 이용하였다.

9) 설명의 편의상 월별 변수만을 이용한 상태공간모형으로 서술하였으나, 실제 전망은 월·분기를 통합한 상태공간모형으로 실시하게 된다. 자세한 내용은 “부록 2) 월·분기 변수를 통합한 상태공간모형”을 참조하라.

했기 때문인지 알 수 없다.

또한, 교량방정식, MIDAS와 같은 모형은 하나의 설명변수에 대해 시차변수까지 포함하여 많은 수의 파라미터를 추정해야 하므로, GDP 성장률 전망과 같이 다수의 경제지표를 포함하여 전망모형을 구성할 경우 신뢰도 높은 파라미터 추정이 어렵다. 이에 대한 대안으로 기존 연구는 각 경제지표에 대해 동일한 구조의 전망모형을 설정하여 전망치를 생성한 다음, 이렇게 생성된 다수의 전망치에 예측조합을 적용하였다. 그러나, 이 경우에도 전망 결과에 대한 일관된 설명이 어렵고, 경제변수 간 관계를 고려하지 못한다는 단점이 있다.

GDP nowcasting 전망모형으로서 기존 모형대비 DFM의 장점은 크게 세 가지로 정리할 수 있다. 먼저, DFM은 많은 수의 변수에서 소수의 공통요인을 추출하여 설명변수로 활용하기 때문에 대규모 거시경제 데이터를 GDP 성장률 예측에 이용할 수 있다. 즉, 대규모 데이터에 포함된 정보를 이용하면서도 상대적으로 추정해야 할 파라미터의 수가 적어 효율적인 전망모형 추정이 가능하다.

다음으로, DFM은 여러 경제변수의 구조적 관계를 모형 내에서 체계적으로 고려할 수 있다. 모형 내 개별 변수의 예측치가 생성되므로 뉴스(=실적치-예측치)가 전망 업데이트에 미치는 영향을 각 경제지표별로 정량적으로 파악할 수 있다. 다변수 모형에 주로 이용되는 칼만 필터는 예측치를 처리하는 과정에서 GDP 성장률뿐만 아니라 모형 내 모든 변수에 대한 예측치를 제공하므로 뉴스를 기반으로 한 전망 업데이트 및 업데이트 변동요인에 대한 분석이

가능하다(Banbura et al., 2013).

마지막으로, DFM을 이용한 기존 연구는 대부분 전체 경제변수를 대상으로 공통요인을 추출하였으나 본 연구는 각 변수를 변수 성격에 따라 블록을 지정한 다음, 블록별로 공통요인을 추출하였다(Kose et al., 2003). 동 방식은 동일한 성격의 데이터 블록에서 요인을 추출하므로 데이터의 공통요인을 보다 효율적으로 추출할 수 있다.

3. 모형 설정

모형에 포함되는 경제변수는 국내외 기존 연구결과와 우리나라 경제구조를 고려하여 선정하였으며, 변수 성격에 따라 글로벌(global), 실물(real), 연성(soft), 노동(labor) 등 4개 블록으로 분류하였다.¹⁰⁾ 특히, 우리나라 경제에서 제조업과 수출입이 차지하는 비중이 큰 점을 고려하여 제조업 생산·출하, 수출입 규모, 수출입 물가지수 등 변수를 포함하였다. 또한, 최근 GDP nowcasting 관련 연구에서 연성자료(soft data)의 중요성이 강조되는 점을 반영하여 소비자 심리지수 등 서베이 자료를 다수 포함하였다.¹¹⁾ 설비투자지수, 제조업 출하지수, 소비자물가지수 등 변수는 정상성(stationarity)을 갖도록 차분, 증가율 등으로 변환하였다. 공표된 계절조정 시계열을 이용하였으며, 계절조정 시계열이 없는 경우 계절더미 변수를 이용하여 계절성을 제거하였다. DFM 전망모형의 입력변수는 국민계정중 국내총생산, 민간소비, 건설투자, 설비투자, 수출 등 5개 분기 변수와 29개 월 변수를 포함

10) 모형에 이용한 데이터 및 변환 방법에 대한 상세한 내용은 “〈부록 1〉 모형에 이용된 변수 목록”에서 설명하였다.

11) Banbura et al.(2013), Kim(2019) 등을 참고하라.

하여 총 34개이며 <그림 1>과 같이 월·분기 변수가 통합된 형태이다.¹²⁾

DFM 파라미터를 추정하는 데이터 표본은 경제변수 간 관계가 변화할 가능성을 감안하여 15년 기준 순차 이동(rolling-window) 방식을 이용하여 정하였다. 예를 들어, 2021년 1분기 GDP nowcasting을 수행하기 위한 GDP 성장률 전망모형은 34개 경제변수의 2006년 1분기부터 2020년 4분기까지의 15개년 관측치를 이용하여 추정한다. 표본 기간을 10년으로 둔 경우에도 전망모형의 예측 오차는 큰 차이를 보이지 않았다. 한편, 표본 시작점을 고정하고 시간이 지남에 따라 표본 기간이 늘어나는 축차(recursive) 방식은 예측 오차를 확대시킬 수 있다는 기존 연구결과를 고려하여 본 연구에서는 적용하지 않았다.

4. GDP nowcasting


DFM을 이용한 실시간 경제전망은 먼저 DFM 전망모형을 추정하고 추정된 전망모형을 이용하여 당분기 GDP 성장률을 예측한 다음, 이후 일정 기간(예, 일주일) 새로 입수되는 자료와 기존 자료 수정을 반영하여 GDP 성장

률 예측치를 업데이트하는 과정으로 이루어진다. 본 연구에서는 전망 대상 분기 직전 월 중순쯤 DFM 전망모형 추정과 함께 GDP 성장률 예측을 시작하여 전망 대상 분기가 끝나고 한 달 정도 지나 GDP 성장률 속보치가 공표될 때까지 실시간 GDP nowcasting을 수행한다(아래 <그림 2>).

1) DFM 추정

EM 알고리즘은 일반적인 패턴의 결측치 문제에 모두 대응할 수 있으며, 최근 Banbura et al.(2013), Bok et al.(2018) 등에서 nowcasting 전망모형 추정에 적용된 이후 각국 중앙은행에서 활용사례가 늘고 있다. EM 알고리즘은 상태공간모형을 이용하여 입력변수의 결측치를 모두 채워넣는 E-step과 주어진 입력변수에서 우도(likelihood)가 극대화되는 파라미터를 찾는 M-step으로 구성된다. 먼저 주성분 분석, 회귀분석 등을 이용하여 DFM 파라미터의 초기값을 추정한 다음, 이후 우도가 국소극대점(local maximum point)으로 수렴할 때까지 E-step과 M-step을 반복한다.¹³⁾

<그림 2> 실시간 경제전망 프로세스(2020년 3분기 예시)



12) 월별 변수와 분기별 변수가 통합된 상태공간모형에 대한 구체적인 내용은 “<부록 2> 월·분기 변수를 통합한 상태공간모형”에 설명하였다. 데이터를 50개 이상으로 추가하더라도 데이터 성격에 맞게 블록을 적절히 설정하면 대체로 유사한 전망 성과를 보이므로 본 모형을 이용한 전망 결과의 강건성을 확인하였다.

13) EM 알고리즘에 대한 보다 자세한 내용은 “<부록 3> EM 알고리즘”에 설명되어 있다.

2. 실시간 경제전망

DFM 파라미터를 추정된 다음에는 전망시점에 입수가능한 모든 관측치가 포함된 빈티지 데이터셋을 이용하여 당분기 GDP 성장률을 예측한다. 칼만 필터링과 스무딩을 통해 공통요인을 전망 대상 분기의 마지막 월까지 예측하고, 이를 이용하여 GDP 성장률을 포함한 모형 내 모든 입력변수에 대해 전망 대상 분기의 마지막 월까지 예측치를 계산한다.¹⁴⁾ 이는 본 전망모형이 단순히 당분기 GDP 성장률을 예측하는데 그치는 것이 아니라, 소비, 투자, 수출입, 물가 등 경제지표에 대한 전망이 함께 이루어지는 것을 의미한다.

신규 데이터 공표, 기존 데이터 수정 등이 있는 경우 이를 반영한 빈티지 데이터셋을 이용하여 GDP 성장률 예측치를 업데이트한다. 동일한 전망모형을 적용하였으므로, 예측치 변동은 새로운 관측치 공표 또는 기존 공표된 데이터의 수정으로 설명된다. 특히, 특정 경제변수의 새로운 관측치가 있는 경우 GDP 성장률 예측치 업데이트를 동 경제변수의 관측치와 기존 예측치의 차이(news)로 설명할 수 있다.

예를 들어, 지난 GDP 성장률 예측에서 3분기 GDP 성장률이 1%, 9월 실업률이 5.5%로 예측되었다고 하자. 이후 실제 9월 실업률이 5%로 발표되고, 이에 따라 3분기 GDP 성장률 예측치가 지난주 대비 0.1%p 상향된 1.1%p라고 하면, 9월 실업률이 예상 0.5%p 하회함에 따라 GDP 성장률 예측치가 0.1%p 상향조정된 것으로 설명할 수 있다.

5. 전망결과

DFM 전망모형의 예측력을 평가하기 위해 앞서 설명한 빈티지 데이터셋을 이용하여 실시간 경제전망의 전망시점별 예측오차를 계산하였다(〈그림 3〉). 예측오차 계산을 위한 기간은 2017년 1분기부터 2021년 3분기까지 19개 분기이다. 매 분기 실시간 경제전망은 DFM 파라미터를 추정된 다음 매주 금요일을 기준으로 빈티지 데이터셋을 구축하고 속보치가 공표될 때까지 당분기 GDP 성장률을 예측하는 순서로 진행된다. DFM 전망모형 예측오차는 예측치와 속보치의 차이로 계산되며, 19개 분기에 대한 전망시점별 제공근평균제곱오차(RMSE, Root Mean Square Error)와 평균절대오차(MAE, Mean Absolute Error)를 계산한 결과는 아래 〈그림 3〉과 같다.¹⁵⁾

그림을 보면 RMSE와 MAE 모두 시간이 지남에 따라 예측 오차가 작아져 실제 경기흐름을 포착하는 모습을 보였다. GDP 성장률 전망모형의 벤치마크 모형으로 주로 이용되는 시차 4인 자기회귀(AR(4))모형과 비교할 경우 전망 분기의 경제지표가 전망모형에 반영되는 시점(-14 week) 이후 AR(4)와 달리 DFM 전망모형의 예측오차가 빠르게 축소되는 모습을 보인다.


전망 대상 분기별 예측오차(속보치 공표 직전 전망 기준)는 대체로 낮은 수준에 분포하므로 모형의 전반적인 예측력은 양호한 수준으로 평가된다(〈그림 4〉). 대부분 분기에서 전망치와 실제치가 0.5%p내로 근접하였으며

14) 입력변수 중 GDP 성장률의 마지막 월 예측치가 당분기 GDP 성장률이다.

15) RMSE는 $\sqrt{\frac{1}{n} \sum_{i=1}^n (\text{전망치}_i - \text{속보치}_i)^2}$, MAE는 $\frac{1}{n} \sum_{i=1}^n |\text{전망치}_i - \text{속보치}_i|$ 의 수식을 이용하여 계산한다.


코로나19 유행으로 인해 경제성장률이 급등락한 2020년 상반기를 제외한 전체 기간에서 예측오차가 1%p 미만을 기록하였다.

〈그림 3〉 전망시점별 예측오차(DFM v. AR(4))



주: 전망시점별 DFM 및 AR(4) 전망모형 예측치의 GDP 성장률 속보치 대비 예측오차(17.1분기 ~ 21.3분기중, 세로축은 예측오차(%p), 가로축은 속보치 공표일 기준 전망시점(week))

〈그림 4〉 DFM 전망모형 예측오차 분포



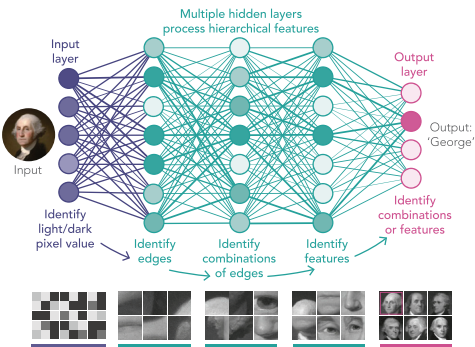
주: 17.1분기 ~ 21.3분기중, 속보치 공표 직전 전망 기준.

IV. ML 전망모형

1. 개요

딥러닝은 인공신경망(artificial neural network)에 기반한 대표적인 기계학습(ML) 알고리즘이다. 인공신경망은 인간 두뇌의 정보 전달 및 처리 과정을 입력·은닉·출력층(input, hidden, output layer)으로 묘사하는 구조를 의미한다. 은닉층이 2개 이상 포함된 인공신경망으로 정의되는 딥러닝은 입력값에 선형결합과 비선형 활성화 함수를 여러 단계 적용하여 출력값을 생성한다(그림 5). 이러한 복잡한 네트워크 구조는 딥러닝 알고리즘이 변수 간 비선형, 상호의존적 관계를 포착할 수 있도록 한다.

〈그림 5〉 딥러닝 인공신경망



주: 입력층(input layer), 3개 은닉층(hidden layer), 출력층(output layer)으로 구성된 이미지인식 딥러닝 알고리즘. 가장 왼쪽에 있는 입력층은 이미지파일의 각 픽셀에서 추출한 RGB값이 저장된 노드(node, 위 그림 파란색 동그라미)로 구성된다. 입력층의 오른쪽에 놓인 첫 번째 은닉층의 각 노드는 입력층의 노드들을 선형결합하고 활성화 함수를 적용하여 계산된다. 선형결합에 이용되는 계수(weight, 각 노드를 연결하는 선)와 절편(bias)이 딥러닝 알고리즘의 파라미터를 구성하며, 활성화 함수로는 sigmoid, tanh, relu 등이 이용된다.

자료: Waldrop (2019)

딥러닝은 음성인식, 이미지인식 등과 같이 주어진 입력에 대응하는 라벨(label)을 예측·분류하는 문제에 주로 활용된다. 예를

들어, 음성인식 딥러닝은 사람의 목소리가 녹음된 음성파일을 입력받아 대응되는 텍스트(단어 또는 문장)를 예측하고, 이미지인식 딥러닝은 이미지파일을 입력받아 이미지가 어떤 동물 또는 누구의 얼굴을 나타내는지 등을 판단한다. 딥러닝의 정확도는 수천, 수만 개에 달하는 파라미터들이 예측문제에 얼마나 최적화되어 있는지에 따라 결정된다. 음성파일과 텍스트, 인물사진과 이름과 같이 입력-라벨 쌍으로 이루어진 데이터셋을 구축한 다음 딥러닝 알고리즘이 각 입력에 대해 맞는 라벨을 출력하도록 파라미터를 최적화하는 과정을 딥러닝 학습(learning)이라고 한다.¹⁶⁾

딥러닝은 콘텐츠 추천(Netflix, Youtube), 인공지능 비서(Alexa, Siri), 자율주행, 안면인식 기반 보안, 챗봇 등 대규모 미시 데이터가 축적된 분야에서 먼저 발전하였다. 최근에는 핀테크 발전과 함께 대규모 데이터 축적과 분석이 활발해진 금융산업에서 부정거래 탐지(fraud detection), 자산배분(asset allocation), 부도위험(default risk) 예측 등 활용 사례가 늘고 있다. 이에 반해, 경제성장률이나 금리, 환율과 같은 거시경제변수 예측에 딥러닝을 이용하려는 시도는 아직 많지 않다.

거시경제변수 예측모형으로서 딥러닝에 대한 관심이 높지 않은 첫 번째 요인은 입력(산업생산지수, 실업률 등 경제지표)과 라벨(미래 GDP 성장률) 간 관계가 일정하지 않다는 것이다. 최근 딥러닝에 대한 관심은 높은 예측력에서 비롯된 것이다. 딥러닝이 높은 예측력을 보이는 음성인식, 이미지인식 등 사례에서는 변

수 간 관계가 시간에 따라 변화하지 않으므로, 충분히 많은 학습데이터를 구축하여 학습시킨면 상당히 높은 예측력을 보인다. 반면, 1년 후 GDP 성장률과 같은 변수는 현재 관측된 경제지표뿐만 아니라 이후 발생할 수 있는 불확실성 확대, 생산성 충격 등 다양한 요인의 영향을 받는다. 이는 전망시계가 길수록 전망대상 변수가 입력변수 이외 요인의 영향을 크게 받아 예측모형의 정확도가 낮아질 수 밖에 없음을 의미한다. 이 경우 변수 간 다층적이지만 일정한 패턴을 학습하는 데 특화된 딥러닝 알고리즘의 장점이 발휘되기 어렵다.


두 번째 요인은 거시경제변수 예측에 딥러닝 알고리즘을 적용할 때 겪게 되는 기술적 어려움이다. GDP 성장률 예측에는 산업생산, 소비·투자, 물가 등과 같은 경제지표의 최근 관측값뿐만 아니라 과거 시차변수를 함께 이용한다. 이는 여러 경제변수들이 일정 주기를 갖고 순환하며(business cycle), 경제 한 부문에 발생한 충격은 시차를 두고 여타 부문으로 파급되는 행태를 보이기 때문이다. 경제변수들이 갖는 이러한 특성을 고려하기 위해서는 시간 순서를 갖는 순차 데이터(sequential data)에 특화된 딥러닝 알고리즘을 이용해야 한다.

순차 데이터에 특화된 대표적인 딥러닝 알고리즘으로 RNN(Recurrent Neural Network), LSTM(Long Short-Term Memory) 등이 있다. RNN은 현재 시점 정보를 입력받아 생성된 은닉층을 다음 시점 은닉층 생성에 활용하는 방식으로 데이터의 시간

16) 딥러닝 모형 학습은 초기 파라미터를 임의로 생성한 다음, 파라미터를 입력변수에 적용하여 라벨을 예측하고 예측과 실제 라벨의 차이(예측오차)가 작아지도록 파라미터를 조정하는 과정을 반복하여 이루어진다. 예측오차를 이용하여 파라미터를 조정하는 대표적 알고리즘으로 경사하강법(gradient descent)이 있다. 연구자가 학습데이터(입력 + 라벨)에 맞는 딥러닝 모형을 설정하면, TensorFlow, PyTorch 등 기계학습 라이브러리는 자동으로 예측오차를 최소화하는 파라미터를 찾아준다.

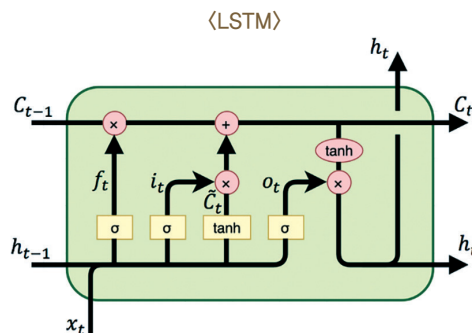
순서를 반영한다(〈그림 6〉). 그러나, 이러한 네트워크 구조에서는 과거 시점에서 생성된 정보가 여러 단계를 거쳐 현재 시점으로 전달되는 과정에서 정보손실이 발생할 수 있다.¹⁷⁾ 이를 보완하기 위해 고안된 LSTM은 각 시점 입력변수의 정보가 이후 시점으로 전달되는 경로를 단기와 장기로 나눔으로써 상대적으로 먼 과거의 정보도 현재 경제변수 예측에 활용되도록 한다.¹⁸⁾

〈그림 6〉 RNN 및 LSTM 알고리즘



주: x_t 는 t 기 입력, h_t 는 t 기에 생성된 은닉층을 의미한다. 전체 RNN 알고리즘에서 t 기 입력과 $t-1$ 기 은닉층을 결합하여 h_t 를 생성하는 단위(위 그림에서 네모로 표시)를 RNN cell이라고 한다. t 기 출력은 h_t 에 속한 노드의 선형결합으로 계산된다.

자료: Amidi and Amidi(2021)



주: 위 그림은 LSTM cell을 나타낸다. x_t 는 t 기 입력, h_t 와 C_t 는 각각 t 기 LSTM cell에서 생성된 hidden state와 cell state를 의미한다. C_t 는 t 기 LSTM cell의 장기정보를 다음 LSTM cell로 전달하는 역할을 수행하며 t 기 출력은 h_t 의 선형결합으로 계산된다.

자료: Olah (2015)

그러나, 이러한 네트워크 구조는 작은 규모의 LSTM 알고리즘을 적용할 경우에도 상당한 프로그래밍 지식과 전산자원을 필요로 함에 따라 활용이 제한적이었다.¹⁹⁾ 그러나 최근 손쉽게 이용할 수 있는 여러 딥러닝 라이브러리가 개발되고 GPU, 메모리 등 딥러닝 학습에 필수적인 전산자원의 성능이 향상되면서 텍스트, 시계열 변수를 분석하는 여러 부문에서 활용 사례가 늘고 있다.²⁰⁾

2. GDP nowcasting

본 연구는 GDP nowcasting을 위한 딥러닝 모형으로 LSTM 알고리즘을 이용하였다. LSTM 알고리즘은 데이터의 시간 구조를 고려하므로 여러 경제변수의 시계열 구조를 파악하고 최근 경제지표를 당분기 GDP 성장률을 예측하는데 활용할 수 있다. 특히, DFM 전망 모형에서 생성된 데이터를 활용함으로써 당분기 GDP 성장률과 월별 경제변수의 관계를 학습하고 실시간 경제전망에 활용할 수 있다(〈그림 7〉 참조).

LSTM 알고리즘 설정 및 학습은 Python 3.8 버전에서 TensorFlow/Keras를 이용하여 수행하였다.

1 LSTM 알고리즘 학습

매 분기 실시간 경제전망에 앞서 DFM 전망 모형을 추정한 다음 LSTM 알고리즘에 기반한

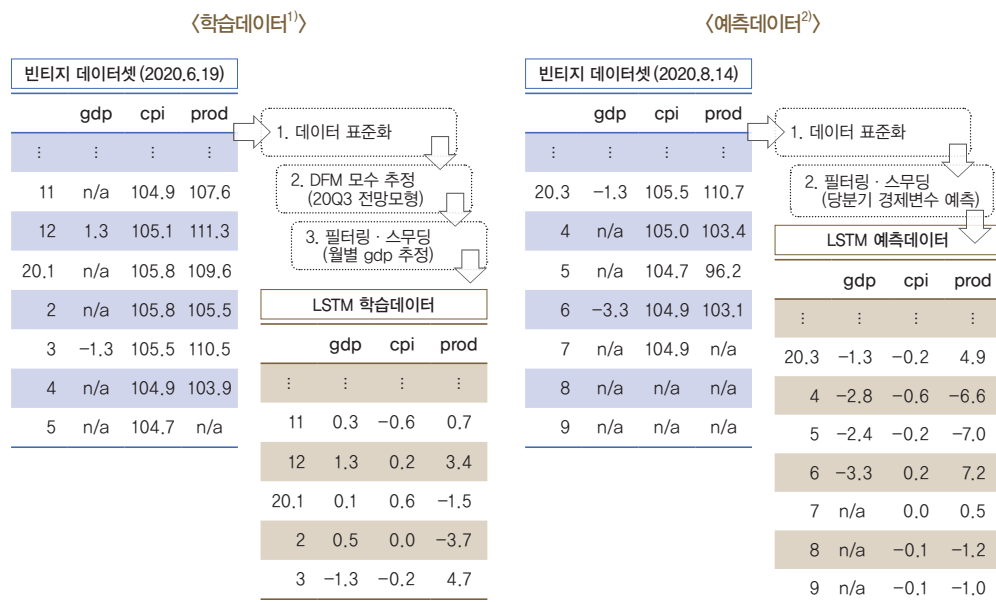
17) 이런 문제로 인해 "The cat, which already ate ..., was full."과 같이 긴 문장의 앞 단어(cat) 문장의 뒷부분(was)까지 영향을 미치는 경우를 해결하기 어려우며(Ng, 2020) 이는 금융 시계열에도 역시 문제가 된다.

18) LSTM은 이를 통해 RNN이 겪는 vanishing gradient 문제(과거 시점의 자료가 중요함에도 모형 내에서의 그 영향력이 시점이 점차 이동함에 따라 급격히 사라지는 현상)을 완화하였다. 인공지능경망, RNN, LSTM에 대한 보다 자세한 설명은 〈부록 4〉 LSTM 알고리즘에 기술하였다.

19) 34개 월별 변수의 과거 15개월간 관측치를 이용하고 100개 노드로 구성된 은닉층을 갖는 LSTM 알고리즘은 55,141개의 파라미터로 구성된다.

20) 최근 LSTM을 이용한 경제변수 예측모형은 Hopp(2021)을 참고하라.

〈그림 7〉 LSTM 학습 및 입력 데이터 생성(20.3분기 기준)



주: 1) 가장 최근 공표된 GDP 성장률의 기준월까지의 데이터로 구성된다. 월별 GDP 성장률 예측치는 학습시점 빈티지 데이터셋을 이용하여 DFM 전망모형을 추정한다. 다음, 빈티지 데이터셋에 걸만 필터링 · 스무딩을 적용하여 추정한다.

2) 전망분기 마지막 월까지의 데이터로 구성되며, 예측치는 전망시점 빈티지 데이터셋에 걸만 필터링 · 스무딩을 적용하여 채워진다. GDP 시차변수는 가장 최근 공표된 GDP 성장률의 기준월까지 데이터를 포함한다.

전망모형을 학습한다.²¹⁾ 일반적으로 딥러닝 학습은 전체 학습데이터를 훈련(training) 및 시험(test) 데이터로 나눈 다음, 훈련데이터를 이용하여 파라미터를 최적화하고 시험데이터를 이용하여 예측력을 평가한다. 파라미터 최적화는 연구자가 설정한 인공지능망 구조(은닉층과 노드 개수)와 학습방법(손실함수, 최적화 방법, 훈련횟수(epoch) 등)²²⁾ 관련 하이퍼파라미터(hyper-parameter) 하에서 예측오차를 최소화하는 파라미터를 찾는 과정으로 이루어진다. 학습된 LSTM 전망모형의 예측력은

DFM에서와 같이 2017년 1분기부터 2021년 3분기까지 GDP 성장률 속보치 대비 전망오차의 RMSE와 MAE로 평가하였다.²³⁾ 하이퍼파라미터는 매 분기 실시간 경제전망의 마지막 전망시점을 기준으로 예측오차가 최소화되는 값을 grid search 방식으로 설정하였다. 한편, 훈련데이터 일부를 검증(validation) 데이터로 나누어 전망모형이 훈련데이터에 과적합(overfitting)되지 않도록 하였다.²⁴⁾

한편, LSTM 알고리즘을 이용하여 GDP 성장률을 예측할 때 이전 몇 개월 또는 몇 년간의

21) 본 연구는 DFM 전망모형에서 생성된 월별 GDP 성장률을 학습데이터에 포함하였다. 월별 GDP 성장률을 학습데이터에서 제외할 경우 대부분 LSTM 하이퍼파라미터 설정에서 예측력이 낮아지는 것으로 나타났다.

22) 딥러닝 파라미터 최적화는 일반적으로 딥러닝 알고리즘의 출력과 라벨의 차이에 손실함수를 적용하여 예측오차를 계산하고, 예측오차를 각 파라미터에 대해 미분하여 얻은 gradient에 비례하여 파라미터를 조정하는 방식으로 이루어진다. 1 epoch은 전체 훈련데이터에 대해 파라미터 조정을 한 차례 수행하는 것을 의미한다.

23) 시계열 변수 전망의 특성상 매 분기 새로운 데이터셋을 이용하여 새로운 전망모형을 학습하게 되므로, 매 분기 마지막 전망시점 GDP 성장률 예측치의 예측오차(RMSE, MAE)를 최소화하도록 하이퍼파라미터를 설정하는 walk-forward validation(rolling base cross-validation)을 적용하였다.

24) 데이터 크기에 비해 파라미터수가 더 많은 특성(over-parametrization)으로 인해 딥러닝 알고리즘은 훈련데이터에 고유한 변수 간 패턴을 학습하여(과적합) 시험데이터에 대한 예측력은 낮고 훈련데이터에 대한 예측력만 높을 수 있다.

월별 경제변수를 예측에 활용할지 결정해야 한다. 동 기간을 관측기간(lookback period)이라고 하며, 관측기간이 12개월이면, 2020년 4분기 GDP 성장률을 예측할 때 2020년 1월부터 2020년 12월까지의 34개 월별 경제변수²⁵⁾ 관측치를 이용하게 된다. LSTM 학습에 이용되는 데이터셋은 아래 <표 2>의 형태로 구성된다.

<표 2> LSTM 학습데이터¹⁾

입력 (34개 월별 경제변수 ²⁾)	라벨 (GDP 성장률 속보치)
19.10월 ~ 20.9월	20.3분기
19.7월 ~ 20.6월	20.2분기
⋮	⋮
04.7월 ~ 05.6월	05.2분기

주: 1) 21.1분기 GDP 성장률 예측을 위해 과거 15년간 데이터를 이용하고 관측기간(lookback period)이 12개월인 경우.

2) 34개 월별 경제변수는 DFM 전망모형으로 결측치가 채워진 월별 GDP 성장률 포함

최종 LSTM 전망모형 학습에 사용한 주요 하이퍼파라미터를 <표 3>에 정리하였다. 먼저, LSTM 전망모형의 관측기간(lookback period)은 15개월로 설정하였다. LSTM 전망모형의 인공신경망 네트워크는 관측기간 15개월에 대응하는 15개 LSTM cell로 이루어진다. 각 LSTM cell은 해당 월의 입력변수를 받아 크기가 100인 은닉상태(hidden state)와 셀상태(cell state)를 생성하여 다음 월의

LSTM cell로 전달하며, GDP 성장률 예측치는 마지막 LSTM cell에서 생성된 은닉층의 노드를 선형결합하여 계산된다.

학습데이터는 DFM(15년)과 달리 전체 데이터를 이용하였다.²⁶⁾ 모형검증을 위한 검증데이터는 훈련데이터의 20%로 설정하였다. 마지막으로 딥러닝 파라미터 추정의 임의성을 고려하여 매 분기 500개 LSTM 전망모형을 학습하고, 실시간 경제전망에서는 각 전망모형에서 생성된 GDP 성장률 예측치 500개의 대푯값을 이용하는 앙상블 기법을 적용하였다.²⁷⁾

<표 3> LSTM 전망모형 하이퍼파라미터

항목	내용
노드 수	100
활성화함수	sigmoid
관측기간	15개월
손실함수	MSE
최적화 방법	Adam Optimizer
dropout	0.0
훈련횟수	3000 epochs
학습데이터	전체 데이터
검증데이터	학습데이터의 20%
앙상블	500회

25) 34개 월별 경제변수는 DFM 전망모형으로 결측치가 채워진 GDP 성장률과 여타 국민계정 항목(소비, 투자 등)을 포함한다. GDP 성장률의 3, 6, 9, 12월 관측치는 실제 공표된 1, 2, 3, 4분기 관측치이며, 나머지 기간은 칼만 필터링·스무딩으로 추정된 값이다.

26) 딥러닝 인공신경망은 구조가 복잡하고 파라미터 수가 많아 학습결과가 데이터 규모에 큰 영향을 받는 것으로 알려져 있다. 본 연구는 15년 및 20년 순차이동, 축치(recursive, 데이터 시작시점을 2001년으로 고정) 방식을 각각 적용하여 예측오차를 평가하였으며, 예측오차가 가장 최소화되는 축치방식을 채택하였다.

27) 딥러닝은 초기 파라미터값의 임의 지정이나 최적화 알고리즘과 같은 학습과정에서의 임의성에 따라 최종 학습된 예측치도 확률변수의 속성을 지닌다. 따라서 모형 자체의 특성에서 오는 예측치의 변동성을 최소화하기 위해 동 분기내에서는 같은 데이터와 알고리즘 구조를 갖는 전망모형을 학습하여 저장하고, 매 주 실시간 전망시에는 DFM에서 당분기 말까지 결측치를 채운 예측데이터를 저장된 LSTM 전망모형들에 적용하여 얻은 전망치의 대푯값(최빈값)을 사용하였다.

2 실시간 경제전망

LSTM 전망모형을 이용한 실시간 경제전망은 DFM 전망모형과 같이 당분기 GDP 성장률 예측치를 매주 업데이트하는 방식으로 진행된다. 먼저, 매주 금요일 DFM 실시간 경제전망에서 생성된 당분기 월별 경제변수 예측치를 입력받아 사전 학습된 LSTM 전망모형에 적용하여 500개 GDP 성장률 예측치를 생성한다. 다음으로, LSTM의 당분기 GDP 성장률 예측은 500개 GDP 성장률 예측치의 최빈값(mode)을 이용한다.²⁸⁾

DFM과 같이 LSTM 실시간 경제전망에서도 지난주 GDP 성장률 예측치와 금주 GDP 성장률 예측치의 차이는 지난 한 주간 신규 공표된 경제지표가 동 경제지표에 대한 기대에서 벗어난 정도(news) 또는 기존 경제지표 수정에 의한 것으로 설명된다. 이를 통해, 현재 경기흐름을 파악하고, 수시 입수되는 경제지표와 현재 경기흐름의 관계를 이해할 수 있다.²⁹⁾

3. 전망 결과

DFM과 LSTM 전망모형을 이용하여 2017년 1분기부터 2021년 3분기까지 기간에 대해 실시간 GDP nowcasting을 실시하고 실제 GDP 성장률 속보치 및 잠정치 대비 예측오차(RMSE, MAE)를 평가하였다(〈그림 8〉). 두 모형 모두 전망시점이 GDP 성장률 속보치 공

표일에 다가갈수록 예측오차가 작아지는 모습을 보였다. 이는 DFM과 LSTM 전망모형 모두 입수된 정보를 효율적으로 활용함을 의미한다. GDP nowcasting에서 한 가지 더 고려할 점은 각 전망시점에서의 성장률 예측치는 해당 시점까지 입수된 경제지표를 반영한 것이므로 실제 GDP 성장률은 이후 경기흐름에 따라 더 높아지거나 낮아질 수 있다는 것이다. GDP nowcasting의 이러한 특성을 고려할 때, 〈그림 8〉의 결과는 두 전망모형이 실제 경기흐름을 잘 포착하는 것으로 해석할 수 있다.³⁰⁾

특히, DFM과 LSTM 전망모형의 예측오차를 비교해보면, 전망시점에 관계없이 LSTM 전망모형의 예측력이 더 높은 것으로 나타났다. 이는 앞서 설명한 바와 같이 인공지능망 구조에 기반한 LSTM 전망모형이 변수 간 비선형 및 상호의존적 관계를 포착하는데 보다 용이할 것이라는 기대에 부합한다.

한편, DFM 전망모형의 경우 GDP 성장률 속보치 대비 예측오차와 잠정치 대비 예측오차가 유사한 수준을 나타냈다. 이에 반해, LSTM 전망모형은 대부분 전망시점에서 잠정치 대비 예측오차가 속보치 대비 예측오차에 비해 낮은 수준을 보였다. 이는 LSTM 전망모형이 DFM 전망모형에 비해 실제 경기상황을 보다 잘 포착하기 때문인 것으로 보인다.

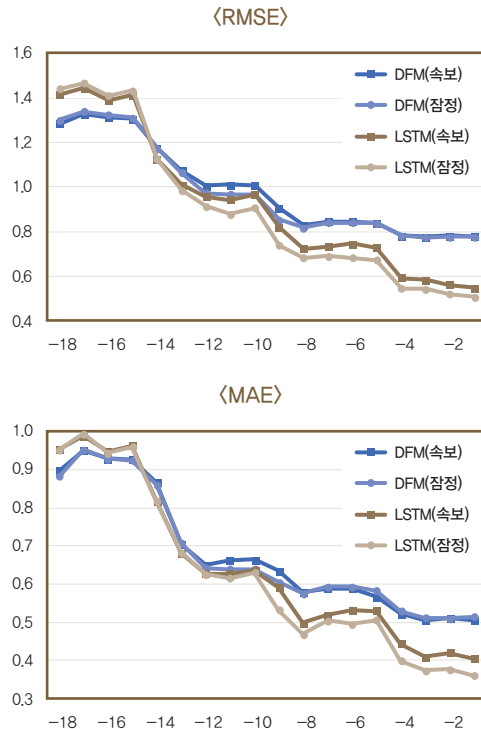
다음으로 〈그림 9〉는 코로나19 팬데믹으로 경제 불확실성이 확대된 2020년 상반기 중 실시간 GDP nowcasting 결과이다.

28) LSTM 전망모형 훈련횟수가 충분히 큰 경우(3000 epochs 이상) 예측치의 평균, 중간값, 최빈값 등은 서로 큰 차이를 보이지 않았으나, 많은 경우 최빈값이 가장 작은 예측오차를 보였다.

29) LSTM 전망모형의 경우 각 빈티지 데이터셋을 신규 공표된 변수별로 분해하는 방식으로 예측치 변동요인을 분해할 수 있다. 예를 들어 2020년 8.7일 이후 일주일간 소비자물가지수와 실업률이 새로 공표되어 8.14일 빈티지 데이터셋(2020-08-14.data)에 포함되었다면, 8.7일 빈티지 데이터셋(2020-08-07.data)에 실업을 공표지만 포함한 데이터셋 2020-08-14-v1.data와 소비자물가지수 공표치도 포함한 2020-08-14-v2.data를 생성하여 실시간 전망을 수행한다.

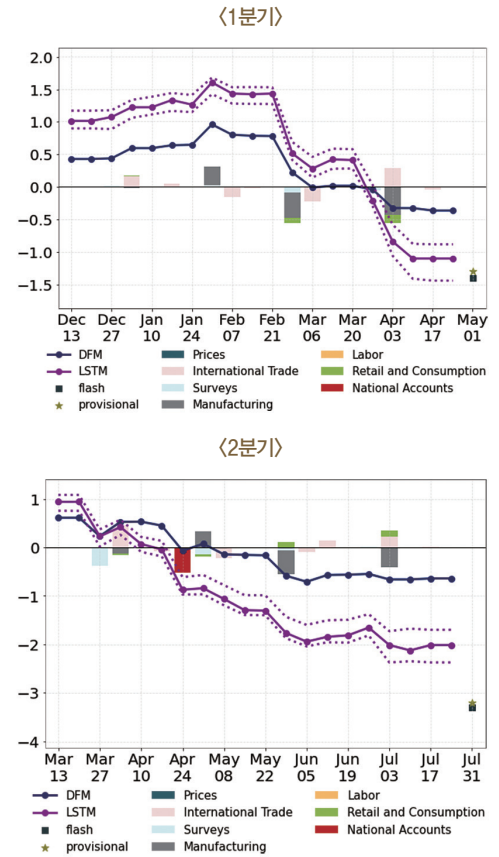
30) 이는 GDP nowcasting 모형의 예측력은 속보치 공표 직전 전망치를 기준으로 평가해야 함을 시사한다.

〈그림 8〉 전망시점별 예측오차(DFM v. LSTM)



주: 각 전망시점별 GDP 성장률 예측치의 속도치 및 잠정치 대비 예측오차(17.1분기 ~ 21.3분기중, 세로축은 예측오차(%), 가로축은 속도치 공표일 기준 전망시점(week))

〈그림 9〉 실시간 경제전망(2020년 상반기)



주: 남색 실선은 DFM, 보라색 실선은 LSTM 전망모형의 전망시점별 GDP 성장률 예측치(가로축은 전망시점, 세로축은 GDP 성장률(%)). 보라색 점선은 500개 LSTM 예측치의 5% 및 95% 분위값. 오른쪽 끝 네모(별) 표시는 GDP 성장률 속도치(잠정치). 막대그래프는 각 전망시점별 DFM 예측치 업데이트의 변수 카테고리별 변동요인분해.

코로나19 유행으로 GDP 성장률이 급락한 2020년 1분기를 보면, DFM과 LSTM 전망모형 모두 1월말부터 지속적으로 성장률 예측치가 하향조정되며, 경기흐름을 적기에 포착할 수 있었던 것으로 보인다. 전망모형별로 보면, DFM 전망모형이 속도치 공표 전 GDP 성장률을 -0.4%로 예측한 반면, LSTM 전망모형은 보다 가파르게 예측치를 업데이트하며 실제 속도치인 -1.4%(잠정치 -1.3%)에 가까운 -1.1% 성장률을 예측하였다.

성장률 예측치가 크게 하락한 2월말-3월초와 4월초 두 기간의 예측치 변동을 요인별로 분해해 보면, 제조업 생산(manufacturing), 소비(retail and consumption) 지표 부진이 가장 크게 작용하였음을 알 수 있다. 다음으로 예측치 변동에 큰 영향을 미친 수출입(international trade)의 경우 2월말-3월초에는 하락 요인으로 작용하였으나 이후에는 성장률 상승 요인으로 나타났다.


2020년 2분기도 GDP 성장률이 크게 하락한 가운데, GDP nowcasting 시스템 예측치도 지속적으로 하향조정되었으나 예측오차는

다소 확대되었다. 2분기 GDP 성장률이 속보치가 1분기 대비 1.9%p 낮은 -3.3%(잠정치 -3.2%)까지 하락하였으나, DFM 전망모형 예측치는 -1%에도 미치지 못하는 것으로 나타났다. LSTM 전망모형의 경우 예측치가 -2%까지 하락하였으나 실제 성장률과는 차이를 보였다.

2020년 2분기 실시간 GDP nowcasting에서 주목할 점은 5월말 이후 DFM과 LSTM 전망모형 모두 성장률 예측치 하락속도가 둔화되었으며, 소폭 상승세를 보이기도 했다는 점이다. 이는 다음 분기인 2020년 3분기 GDP 성장률이 2% 수준으로 반등하였다는 사실에 부합하는 것으로, 실시간 GDP nowcasting이 현재 경기흐름을 적시 파악하는데 활용될 수 있음을 시사한다.

실제 GDP 성장률이 반등한 2020년 3분기(<그림 10>)를 보면 분기 첫 번째 월인 7월부터 DFM과 LSTM 전망모형 모두 성장률 예측치가 가파르게 상승하는 모습을 보였으며, 9월경 이미 실제 3분기 GDP 성장률 속보치인 1.9%(잠정치 2.1%)에 근접하는 것으로 나타났다.

(그림 10) 실시간 경제전망(2020년 3분기)



V. 요약 및 시사점

본 연구는 현재 경기흐름에 대한 신속하고 정확한 판단지표를 제공하기 위해 실시간 당분기 경제전망 시스템을 개발하였다. 동 시스템은 주요국 중앙은행에서 GDP nowcasting 모형으로 활용되는 계량경제모형에 최근 빠르게 발전한 기계학습 알고리즘을 적용하여 전망결과의 설명력과 예측력을 제고하고자 하였다.

이를 위해 본 연구는 DFM과 LSTM 두 전망모형을 보완적으로 활용하고, 실시간 경제전망 프로세스를 통해 현재 경기흐름을 일관되게 파악할 수 있도록 실시간 GDP nowcasting 시스템을 구축하였다. 동 시스템은 여러 경제지표 간 구조적 관계를 고려하고, 데이터에 내재된 변수 간 비선형, 상호의존적 관계를 포착하여 경제전망의 예측력을 높일 수 있었다.

DFM과 LSTM 전망모형으로 구성된 실시간 GDP nowcasting 시스템은 실제 경기흐름을 적절히 포착하는 것으로 나타났다. DFM과 LSTM 전망모형 모두 2020년 1분기와 2분기의 급격한 GDP 성장률 하락, 2020년 3분기의 GDP 성장률 반등을 조기에 포착한 것으로 나타났다. 특히, LSTM 전망모형은 코로나19 유행과 같이 경제 불확실성이 확대된 상황에서 상대적으로 높은 예측력을 보였다. 이는 인공지능망 구조에 기반한 LSTM 알고리즘이 변수 간 비선형, 상호의존적 관계를 포착하는데 효과적이기 때문인 것으로 판단된다.

본 시스템은 다양한 고빈도 경제지표를 반영하여 당분기 GDP 성장률 예측치를 업데이트하는 프로세스를 통해 현재 경기상황 뿐만

아니라 다양한 경제지표를 어떻게 해석할지 판단하는 참고지표를 제공한다. 경제전망에 활용할 수 있는 다양한 대체데이터 발굴, 전망모형 개선 등의 노력이 지속적으로 이어진다면, 동 시스템의 데이터 기반 실시간 경제전망과 숙련된 경제전망 담당자의 정성적 판단을 보완적으로 활용하여 현재 경기흐름에 대한 보다 신속하고 정확한 판단에 근거한 정책수행이 가능할 것으로 기대된다.

최근 주요국 중앙은행, 국제기구 등은 기계학습과 같은 분석기법을 빅데이터에 적용하여 경제전망의 적시성과 정확도를 높이기 위해 노력하고 있다. 본 연구는 기계학습 알고리즘뿐만 아니라 기존 빅데이터 기반 경제전망 연구 성과가 축적된 계량경제모형을 상호보완적으로 활용하여 예측력 높은 GDP nowcasting 시스템을 개발하였다. 이러한 성과는 점차 중요성이 높아지고 있는 다양한 빅데이터 및 기계학습 알고리즘을 효과적으로 활용하는 방안을 제시한다는 점에서도 의미가 크다고 할 수 있다.

〈부록 1〉

모형에 이용된 변수 목록

구분	변수명	단위	블록설정				변환 방법
			Global	Real	Soft	Labor	
국민계정 (5)	국내총생산	%(실질, 전기비)	○	○			0
	민간소비		○	○			0
	건설투자		○	○			0
	설비투자		○	○			0
	수출		○	○			0
노동시장 (5)	실업률	%	○			○	0
	고용률		○			○	0
	구직배수		○			○	0
	취업률		○			○	0
	총취업자수	천명	○			○	2
대외부문 (4)	수출	백만	○	○			2
	수입	달러	○	○			2
	수입물가지수	2015 = 100	○				2
	수출물가지수		○				2
소비, 물가 (5)	소매판매액지수		○	○			2
	소비자물가지수		○				2
	생산자물가지수		○				2
	소비자물가지수 (농산물 및 석유류제외)		○				2
	소비자물가지수 (식료품 및 에너지제외)		○				2
생산, 제조 (5)	설비투자지수		○	○			1
	제조업출하지수		○	○			2
	제조업재고지수		○	○			2
	서비스업생산지수		○	○			1
	광공업생산지수		○	○			2
서베이 (10)	전산업 매출 BSI	-	○		○		0
	전산업 업황 BSI		○		○		0
	제조업 수출 BSI		○		○		0
	제조업 가동률 BSI		○		○		0
	제조업 신규수주 BSI		○		○		0
	제조업 내수판매 BSI		○		○		0
	제조업 업황 BSI		○		○		0
	경제심리지수		○		○		0
	현재경기판단 CSI		○		○		0
	소비자심리지수		○		○		0

주: 1) 변환 방법 : 0 - 원자료 / 1 - 차분 / 2 - 로그 차분

〈부록 2〉

월·분기 변수를 통합한 상태공간모형

1. 월별 변수(x_t)만을 이용한 상태공간모형 구성

이하의 상태공간모형 설정 과정은 주로 Banbura et al. (2010)을 따르도록 한다. 월별 경제변수(x_t)는 공통요인(f_t)과 개별요인(ε_t)의 선형 결합으로 이루어지며, 공통요인(f_t)이 VAR(1)과정을 따르고, 개별요인(ε_t)은 AR(1)과정을 따른다는 가정 하에 월별 변수만을 이용하여 상태공간모형을 구축하였다.

$$[\text{관측식}] \quad x_t = Cf_t + \varepsilon_t$$

$$\varepsilon_{i,t} = \alpha_i \varepsilon_{i,t-1} + e_{i,t} \quad (e_{i,t} \sim iid \ N[0, \sigma_i^2])$$

$$[\text{전이식}] \quad f_t = Af_{t-1} + u_t \quad (u_t \sim iid \ N[0, Q])$$

이때 월별 변수에서 요인(factor)을 추출하므로 요인 또한 월별 주기를 따른다. 데이터의 성격을 고려하여 4개의 블록(Global, Real, Soft, Labor)을 설정한 후 월별지표의 관측식에 블록을 고려한 제약을 설정하면 다음과 같다.

$$f_t = (f_t^G, f_t^R, f_t^S, f_t^L)'$$

$$\begin{pmatrix} x_t^G \\ x_t^R \\ x_t^S \\ x_t^L \end{pmatrix} = \begin{pmatrix} C_{G,G} & 0 & 0 & 0 \\ C_{R,G} & C_{R,R} & 0 & 0 \\ C_{S,G} & 0 & C_{S,S} & 0 \\ C_{L,G} & 0 & 0 & C_{L,L} \end{pmatrix} f_t + \begin{pmatrix} \varepsilon_t^G \\ \varepsilon_t^R \\ \varepsilon_t^S \\ \varepsilon_t^L \end{pmatrix}$$

이 때 월별지표의 전이식은 다음과 같이 설정된다.

$$f_t = \underbrace{\begin{pmatrix} a_G & 0 & 0 & 0 \\ 0 & a_R & 0 & 0 \\ 0 & 0 & a_S & 0 \\ 0 & 0 & 0 & a_L \end{pmatrix}}_A f_{t-1} + u_t$$

$$Q = \begin{pmatrix} Q_G & 0 & 0 & 0 \\ 0 & Q_R & 0 & 0 \\ 0 & 0 & Q_S & 0 \\ 0 & 0 & 0 & Q_L \end{pmatrix}$$

2. 분기 변수와 월별 변수 간의 관계

Mariano and Murasawa(2003)에 근거하여 분기 변수를 월별 변수와 통합하기 위해 우선 관측 불가능한 전월대비 GDP 성장률($y_t^M = Y_t^M - Y_{t-1}^M = 100 \times [\log GDP_t^M - \log GDP_{t-1}^M]$)이 다음과 같은 요인모형을 따른다고 가정한다. 이때, Y_t^M 는 t 기의 월별 GDP에 로그를 취하여 100을 곱한 것이다. ($Y_t^M = 100 \times \log GDP_t^M$)

$$y_t^M = C_Q f_t + \varepsilon_t^Q$$

$$\varepsilon_t^Q = \alpha_Q \varepsilon_{t-1}^Q + e_t^Q \quad (e_t^Q \sim iid N[0, \sigma_Q^2])$$

본 연구에서 분기 지표는 모두 Real 블록에 속하므로 관측식에 다음과 같이 계수에 제약을 설정하였다.

$$y_t^M = (C_{Q,G} \quad C_{Q,R} \quad 0 \quad 0) f_t + \varepsilon_t^Q$$

이때, GDP의 전분기대비 성장률($y_t^Q = Y_t^Q - Y_{t-3}^Q = 100 \times [\log(GDP_t^Q) - \log(GDP_{t-3}^Q)]$)을 다음과 같이 전월대비 성장률로 나타낼 수 있다.

$$\begin{aligned} y_t^Q &= Y_t^Q - Y_{t-3}^Q \approx (Y_t^M + Y_{t-1}^M + Y_{t-2}^M) - (Y_{t-3}^M + Y_{t-4}^M + Y_{t-5}^M) \\ &= y_t^M + 2y_{t-1}^M + 3y_{t-2}^M + 2y_{t-3}^M + y_{t-4}^M \\ &= C_Q f_t + 2C_Q f_{t-1} + 3C_Q f_{t-2} + 2C_Q f_{t-3} + C_Q f_{t-4} + \varepsilon_t^Q + 2\varepsilon_{t-1}^Q + 3\varepsilon_{t-2}^Q + 2\varepsilon_{t-3}^Q + \varepsilon_{t-4}^Q \end{aligned}$$

3. 월별변수와 분기변수를 통합한 상태공간모형

앞서 구한 식을 이용하여 월별변수와 분기변수를 통합한 상태공간모형을 다음과 같이 구축할 수 있다.

[관측식]

$$\begin{pmatrix} x_t \\ y_t^Q \end{pmatrix} = \begin{pmatrix} C & 0 & 0 & 0 & 0 & I_n & 0 & 0 & 0 & 0 \\ C_Q & 2C_Q & 3C_Q & 2C_Q & C_Q & 0 & 1 & 2 & 3 & 2 & 1 \end{pmatrix} \begin{pmatrix} f_t \\ f_{t-1} \\ f_{t-2} \\ f_{t-3} \\ f_{t-4} \\ \varepsilon_t \\ \varepsilon_t^Q \\ \varepsilon_{t-1}^Q \\ \varepsilon_{t-2}^Q \\ \varepsilon_{t-3}^Q \\ \varepsilon_{t-4}^Q \end{pmatrix}$$

[전이식]

$$\begin{pmatrix} f_t \\ f_{t-1} \\ f_{t-2} \\ f_{t-3} \\ f_{t-4} \\ \varepsilon_t \\ \varepsilon_t^Q \\ \varepsilon_{t-1}^Q \\ \varepsilon_{t-2}^Q \\ \varepsilon_{t-3}^Q \\ \varepsilon_{t-4}^Q \end{pmatrix} = \begin{pmatrix} A & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ I_r & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & I_r & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & I_r & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & I_r & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & I_r & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \text{diag}(\alpha_1, \dots, \alpha_n) & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \alpha_Q & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} f_{t-1} \\ f_{t-2} \\ f_{t-3} \\ f_{t-4} \\ f_{t-5} \\ \varepsilon_{t-1} \\ \varepsilon_{t-1}^Q \\ \varepsilon_{t-2}^Q \\ \varepsilon_{t-3}^Q \\ \varepsilon_{t-4}^Q \\ \varepsilon_{t-5}^Q \end{pmatrix} + \begin{pmatrix} u_t \\ 0 \\ 0 \\ 0 \\ 0 \\ e_t \\ e_t^Q \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

〈부록 3〉

EM 알고리즘

EM 알고리즘은 Expectation-step(E-step)과 Maximisation-step(M-step)을 기대우도가 수렴할 때까지 번갈아가며 반복하여 파라미터를 추정하며, 데이터에 결측치가 존재하는 경우에도 적용할 수 있다는 장점이 있다. Banbura and Modugno(2014)는 결측치가 임의의 패턴을 보이는 경우에도 EM 알고리즘을 적용할 수 있도록 확장하였으며, 당분기 경제성장률 전망과 같이 주기불일치로 인한 결측치가 있는 데이터셋에 적합한 동적요인모형을 설정하고 추정하였다. Banbura and Modugno(2014) 이후 nowcasting을 위한 동적요인모형 추정에 EM 알고리즘에 기반한 최대우도추정법 활용 사례가 늘고 있다(Bok et al. (2018) 등).

E-step은 이전 반복에서의 파라미터를 기반으로 칼만필터링과 스무딩을 통해 결측치를 기입(fill-in)한 후 기대우도를 추정하는 단계이다.

$$L(\theta, \theta(j)) = E_{\theta(j)}[l(Y, F; \theta) | \Omega_T]$$

($Y = [y_1, \dots, y_T]$, $F = [f_1, \dots, f_T]$)이며, $l(Y, F; \theta)$ 은 Y 와 F 의 결합 로그우도)

M-step은 기대우도를 극대화하는 파라미터를 재추정하는 과정이다.

$$\theta(j+1) = \operatorname{argmax}_{\theta} L(\theta, \theta(j))$$

특정 정규성 조건(regularity condition)하에서 EM 알고리즘은 우도의 국소 극대점(local maximum)으로 수렴하는 것으로 알려져 있다.

〈부록 4〉

LSTM 알고리즘

인공신경망은 인간의 뉴런 및 시냅스 간 정보 전달 과정을 입력(input) - 은닉(hidden) - 출력(output) 층으로 모형화한 것으로서 특히 은닉층이 여럿(적어도 둘 이상) 모인 경우를 딥러닝이라고 부른다. 이 중 시계열과 같이 연속된 자료(sequence)를 모형화하는 방법으로서 RNN, GRU, LSTM, Transformer와 같이 딥러닝 네트워크를 순차적으로 연결한 방법론이 다수 연구되었다. 본 연구에서 활용한 LSTM(Hochreiter et al., 1997)은 현재까지도 산업계와 전망모형 등 다양한 곳에서 이용되며 안정성을 검증받은 모형이다. 특징적인 것은 과거 시점의 정보 중 현재 시점의 정보와 관련된 것을 선별적으로 기억하는 구조를 가지고 있다는 점이다.

$$\tilde{c}^{<t>} = \tanh(W_c[a^{<t-1>}, x^{<t>}] + b_c) \quad [1]$$

$$\Gamma_u = \sigma(W_u[a^{<t-1>}, x^{<t>}] + b_u) \quad [2]$$


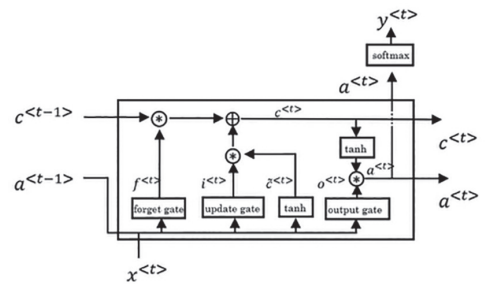
$$\Gamma_f = \sigma(W_f[a^{<t-1>}, x^{<t>}] + b_f) \quad [3]$$

$$\Gamma_o = \sigma(W_o[a^{<t-1>}, x^{<t>}] + b_o) \quad [4]$$

$$c^{<t>} = \Gamma_u * \tilde{c}^{<t>} + \Gamma_f * c^{<t-1>} \quad [5]$$

$$a^{<t>} = \Gamma_o * \tanh c^{<t>} \quad [6]$$

$$\hat{y}^{<t>} = \text{softmax}(a^{<t>}) \quad [7]$$



출처: Ng(2020)

위 식과 그림에서 현재시점 t 에서의 입력변수는 $x^{(t)}$ 로, 직전시점에서 승계되어 온 자료는 $c^{(t-1)}$ 과 $a^{(t-1)}$ 로, 이런 정보를 이용해서 계산한 출력값(전망치)은 $y^{(t)}$ 로 표시한다. 이번기의 출력값을 계산하기 위한 후보(candidate)으로서 $\tilde{c}^{(t)}$ 을 [1]과 같이 계산한다. 이를 계산하기 위해 사용된 값을 보면, $[a^{(t-1)}, x^{(t)}]$ 는 두 벡터를 세로로 나란히 쌓은 것이며, W_c 는 여기에 곱해지는 파라미터 행렬, b_c 는 상수항(bias) 벡터이다. 이 값은 \tanh 와 같은 함수를 통과하면서 값이 $(-1, 1)$ 사이로 한정되는데 이러한 역할을 하는 함수를

활성함수(activation function)라고 한다. 활성함수는 데이터의 특성에 따라 Sigmoid ($\sigma(x)=1/(1+e^{-x})$), Softmax($e^{x_i}/\sum_j^K e^{x_j}$), ReLU($\max(0,x)$), Leaky ReLU($\max(0.1x,x)$) 등으로 다양하게 설정할 수 있다.

LSTM에서 특기할 만한 사항은 전술한 후보값을 활용할지(update), 전기로부터 이전 받은 값($c^{(t-1)}$)을 잊을지(forget) 여부를 각각 (0,1) 사이의 가중치로서 결정하여 $c^{(t)}$ 에 저장해주는 소자(Γ_u, Γ_f)가 존재한다는 것이다. 각 소자를 계산할 때도 $[a^{(t-1)}, x^{(t)}]$ 데이터는 공히 쓰이나 소자에 따라 훈련되는 파라미터가 달라진다(W_u, W_f, W_o) [2~4]. $c^{(t)}$ 는 이번기에 활용되면서 다음기로도 보내진다[5]. 이번기에는, $c^{(t)}$ 에 저장된 값을 얼마만큼 출력(output)부로 보내어 활용할지 여부를 결정해주는 소자(Γ_o)가 존재한다[6]. 이러한 과정을 통과하고 난 값은 $a^{(t)}$ 에서 다음기로 보내지고, 또 이번기에는 Softmax 활성함수를 통과한 뒤 최종 출력값(예측치, \hat{y})이 된다[7].

이러한 파라미터들은 예시 데이터인 x 와 y 의 쌍을 모형에 공급하여 실제값(y)과 예측치(\hat{y}) 간 오류가 최소화되도록 추정하는 감독학습(supervised learning) 과정을 거쳐 얻어진다. 파라미터를 찾는 구체적 방법으로는 SGD, RMSProp, Adam(본고 활용) 등의 최적화 기법이 활용된다. 이 외에도 모형구조, 학습방식 등 하이퍼파라미터(hyperparameter)를 설정(tuning)하는 과정에 대해서는 아직은 일정한 법칙이 존재하지 않으므로 연구자가 데이터의 특성을 고려한 실험적 과정을 통해 LSTM의 형태를 결정하고 데이터의 행태에 따라 이를 개선한다.

〈참고문헌〉

- 김덕파, 강성진, 이선주, 최시원 (2020), “월별지표를 이용한 GDP추정을 위한 계량모형 구축,” 국회예산정책처 정책연구용역 보고서.
- 김치호, 김현정 (2016), “GDP 성장률의 Nowcasting 에 관한 연구,” 한국은행 국민계정리뷰 2016년 제2호.
- 박강우, 이중식 (2009), “GDP 예측력 제고를 위한 동태요인모형 구축,” 한국은행 조사통계월보 2009년 6월호.
- 이동수 (2013), “전산업생산지수를 이용한 분기 성장률 예측,” 통계연구, 제18권 제2호, 66-88.
- 이동진, 이은경 (2017), “실물 · 금융 정보를 종합적으로 활용한 경기상황지수(BOK-COIN) 시산,” 한국은행 조사통계월보 2017년 11월호.
- 이승윤, 이은경, 한진현 (2017), “기계학습과 혼합주기 모형을 활용한 단기전망시스템,” 한국은행 조사통계월보 2017년 5월호, 16-41.
- 최동규 (2020), “인공지능으로 설명한 환율(딥러닝과 그 설명모형을 이용한 단기 환율예측),” 한국은행 행내현상논문.
- 최병재, 한진현 (2014), “월별자료를 이용한 예측조합에 의한 GDP 전망,” 한국은행 경제전망보고서 2014년 10월호, 16-48.
- 황선웅, 박문수 (2012), “대규모 혼합주기 자료를 이용한 단기 경제전망 모형 구축,” 산업연구원 연구보고서 2012-642.
- 형남원, 최경욱, 최병재 (2016), “혼합자료 샘플링 모형을 통한 GDP 예측,” 국제경제연구 제22권 제2호, 83-117.
- Afshine Amidi and Shervine Amidi (2021), “Recurrent Neural Networks cheatsheet,” Stanford CS 230 Deep Learning. URL:<https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-recurrent-neural-networks>
- Anderson, Roy M., Hans Heesterbeek, Don Klinkenberg, and T. Dierdre Hollingsworth (2020), “How Will Country-based Mitigation Measures Influence the Course of the Covid-19 Epidemic?,” The Lancet, Vol.395(10228), 931-934.
- Anesti, Nikoleta, Simon Hayes, Andre Moreira, and James Tasker (2017), “Peering into the present: the Bank's approach to GDP nowcasting,” Bank of England Quarterly Bulletin 2017 Q2.

- Bañbura, Marta, Domenico Giannone, and Lucrezia Reichlin (2010), “Nowcasting,” ECB Working Paper No. 1275.
- Bañbura, M., Giannone, D., Modugno, M., & Reichlin, L. (2013), “Now-casting and the real-time data flow,” *Handbook of economic forecasting* Vol. 2, 195-237 Elsevier.
- Bañbura, Marta, and Michele Modugno (2014), “Maximum likelihood estimation of factor models on datasets with arbitrary pattern of missing data,” *Journal of Applied Econometrics* 29 (1), 133-160.
- Bell, Venetia, Lai Wah Co, Sophie Stone, and Gavin Wallis (2014), “Nowcasting uk gdp growth,” *Bank of England Quarterly Bulletin* 2014 Q1.
- Bhadury, Soumya, Saurabh Ghosh, and Pankaj Kumar (2020), “Nowcasting Indian GDP growth using a Dynamic Factor Model,” RBI Working Paper Series No. 03.
- Bok, Brandyn, Daniele Caratelli, Domenico Giannone, Argia M. Sbordone, and Andrea Tambalotti (2018), “Macroeconomic nowcasting and forecasting with big data,” *Annual Review of Economics* 10, 615-643.
- Chernis, Tony, and Rodrigo Sekkel (2017), “A dynamic factor model for nowcasting Canadian GDP growth,” *Empirical Economics* 53 (1), 217-234.
- Chernis, Tony, and Rodrigo Sekkel (2018), “Nowcasting Canadian Economic Activity in an Uncertain Environment,” No. 2018-9, Bank of Canada.
- Chikamatsu, Koysuke, Naohisa Hirakata, Yosuke Kido, Kazuki Otaka (2018), “Nowcasting Japanese GDPs,” Bank of Japan Working paper No.18-E18, Bank of Japan.
- Cimadomo, J., Giannone, D., Lenza, M., Monti, F., & Sokol, A. (2020), “Nowcasting with large Bayesian vector autoregressions,” ECB Working Paper No. 20202453.
- Doerr, S., Gambacorta, L., & Garralda, J. M. S. (2021), “Big data and machine learning in central banking,” BIS Working Papers No. 930.
- Eraslan, Sercan, and Maximilian Schroder (2019), “Nowcasting GDP with a large factor model space,” *Deutsche Bundesbank Discussion Paper* No. 41/2019.
- Foroni, Claudia, and Massimiliano Giuseppe Marcellino (2013), “A survey of econometric methods for mixed-frequency data,” *Norges Bank Working Paper* No. 2013-06.

- Galvez-Soriano, Oscar de J. (2020), "Nowcasting Mexico's quarterly GDP using factor models and bridge equations," *Estudios Economicos* (Mexico, DF) 35 (2), 213-265.
- Ghysels, E., Sinko, A., & Valkanov, R. (2007), "MIDAS regressions: Further results and new directions," *Econometric reviews* 26 (1), 53-90.
- Giannone, Domenico, Lucrezia Reichlin, and David Small (2008), "Nowcasting: The real-time informational content of macroeconomic data," *Journal of Monetary Economics* 55 (4), 665-676.
- Goulet Coulombe, P., Leroux, M., Stevanovic, D., & Surprenant, S. (2020), "How is machine learning useful for macroeconomic forecasting?," *arXiv e-prints*, arXiv-2008.
- Higgins, Patrick C. (2014), "GDPNow: A Model for GDP'Nowcasting'," *Federal Reserve Bank of Atlanta Working Paper No. 2014-7*.
- H2O (2021, Jul 10), "H2O documentation," H2O.ai. URL: <https://h2o-release.s3.amazonaws.com/h2o/rel-xu/5/docs-website/h2o-docs/index.html>
- Hochreiter, S., & Schmidhuber, J. (1997), "Long short-term memory," *Neural computation* 9 (8), 1735-1780.
- Hopp, D. (2021), "Economic Nowcasting with Long Short-Term Memory Artificial Neural Networks (LSTM)," *UNCTAD Research Paper No. 62*.
- Itkonen, Juha, and Petteri Juvonen (2017), "Nowcasting the Finnish economy with a large Bayesian vector autoregressive model," No. 6/2017. *BoF Economics Review*.
- Jung, J. K., Patnam, M., & Ter-Martirosyan, A. (2018), "An algorithmic crystal ball: Forecasts-based on machine learning," *IMF Working Paper*.
- Kim, Hyun Hak, & Norman R. Swanson (2018), "Methods for backcasting, nowcasting and forecasting using factor-MIDAS: With an application to Korean GDP," *Journal of Forecasting* 37 (3), 281-302.
- Kose, M. A., Otrok, C., & Whiteman, C. H. (2003). "International business cycles: World, region, and country-specific factors," *American Economic Review* 93 (4), 1216-1239.
- Kurz-Kim, Jeong-Ryeol. (2019), "A note on the predictive power of survey data in nowcasting euro area GDP," *Journal of Forecasting* 38 (6), 489-503.

- Liebermann Joelle (2014), “Real-Time Nowcasting of GDP: A Factor Model vs. Professional Forecasters,” *Oxford Bulletin of Economics and Statistics* 76 (6), 783-811.
- Mariano, Roberto S., & Yasutomo Murasawa (2003), “A new coincident index of business cycles based on monthly and quarterly series,” *Journal of applied Econometrics* 18 (4), 427-443.
- Mullainathan, S., & Spiess, J. (2017), “Machine learning: an applied econometric approach,” *Journal of Economic Perspectives* 31 (2), 87-106.
- Ng, Andrew. (2020), “Recurrent Neural Networks,” Lecture note on Sequence Models, DeepLearning.AI and Coursera.
- Olah. (2015), “Understanding LSTM Networks,” Colah’s Blog. URL: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- Qureshi, S., Chu, B. M., & Demers, F. S. (2020), “Forecasting Canadian GDP growth using XGBoost,” *Carleton Economic Papers No. 20-14*, Carleton University, Department of Economics, revised 24 Aug 2020.
- Richardson, A., van Florenstein Mulder, T., & Vehbi, T. (2021), “Nowcasting GDP using machine-learning algorithms: A real-time assessment,” *International Journal of Forecasting* 37 (2), 941-948.
- Schmith, Adrian Michael Bay & Grenestam, Erik (2021), “A factor model approach to nowcasting Danish GDP,” *Danmarks National Bank Economic memo No. 3*.
- Schumacher, Christian. (2014), “MIDAS and bridge equations,” *Deutsche Bundesbank Discussion paper No. 26-2014*.
- Schumacher, Christian. (2016), “A comparison of MIDAS and bridge equations,” *International Journal of Forecasting* 32 (2), 257-270.
- Waldrop, M. Mitchell. (2019), “News Feature: What are the limits of deep learning?,” *Proceedings of the National Academy of Sciences* 116 (4), 1074-1077.

Copyright © THE BANK OF KOREA. All Rights Reserved

- 본 자료의 내용을 인용하실 때에는 반드시 “BOK 이슈노트 No. 2022-7에서 인용”하였다고 표시하여 주시기 바랍니다.
- 자료 내용에 대하여 질문 또는 의견이 있는 분은 커뮤니케이션국 커뮤니케이션기획팀(02-759-4759)으로 연락하여 주시기 바랍니다.
- 본 자료는 한국은행 홈페이지(<http://www.bok.or.kr>)에서 무료로 다운로드 받으실 수 있습니다.