# Word Embedding

# 워드 임베딩(Word Embedding)

희소 표현(sparse representation) vs 밀집 표현(dense representation)

- 희소 표현
  - 원-핫 벡터 (0과 1) 등
  - Ex) 강아지 = [ 0 0 0 0 1 0 0 0 0 0 0 0 ... 중략 ... 0] # 이때 1 뒤의 0의 수는 9995개.
  - 공간적 낭비, 단어의 의미를 표현하지 못함
- 밀집 표현
  - LSA, Word2Vec, FastText, Glove 등
  - 사용자가 설정한 값으로 모든 단어의 벡터 표현의 차원을 맞춤
  - Ex) 강아지 = [0.2 1.8 1.1 -2.1 1.1 2.8 ... 중략 ...] # 이 벡터의 차원은 128
  - 단어를 밀집 벡터(dense vector)의 형태로 표현하는 방법을 워드 임베딩(word embedding)이라고 함

| | 원-핫 벡터 | 임베딩 벡터 |
|---|---|---|
| 차원 | 고차원(단어 집합의 크기) | 저차원 |
| 다른 표현 | 희소 벡터의 일종 | 밀집 벡터의 일종 |
| 표현 방법 | 수동 | 훈련 데이터로부터 학습함 |
| 값의 타입 | 1과 0 | 실수 |

# 워드투벡터(Word2Vec)

**분산 표현**(Distributed Represetation)

- 희소 표현은 단어 벡터간 유사성 표현 불가 → 의미를 다차원 공간에 벡터화
- '분포 가설' 가정 ('비슷한 문맥에서 등장하는 단어들은 비슷한 의미를 가진다')
- 저차원에 단어의 의미를 여러 차원에다가 분산하여 표현
- 단어 벡터 간 유의미한 유사도 계산 가능

분산 표현의 대표적인 학습 방법인 Word2Vec(2013) 부터 알아보자.

Word2Vec의 학습 방식에는 **CBOW(Continuous Bag of Words)**와 **Skip-Gram** 두 가지 방식이 있음

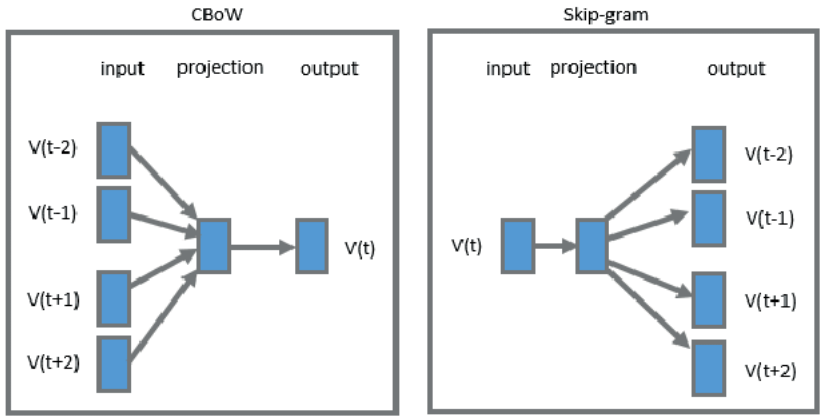

# 워드투벡터(Word2Vec)

CBOW(Continuous Bag of Words)

- 주변에 있는 단어들을 입력으로 중간에 있는 단어들을 예측하는 방법

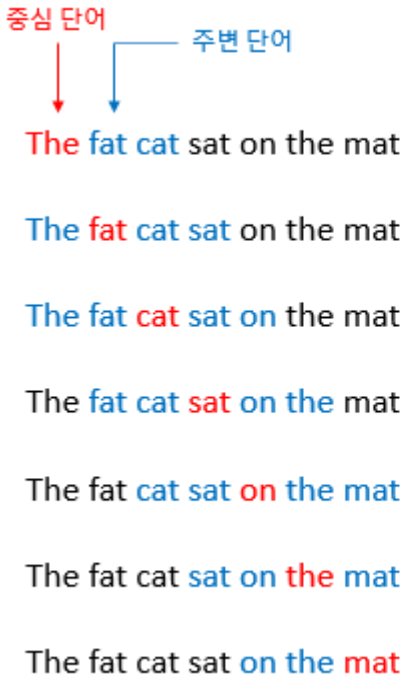


| 중심 단어 | 주변 단어 |
|---|---|
| [1, 0, 0, 0, 0, 0, 0] | [0, 1, 0, 0, 0, 0, 0], [0, 0, 1, 0, 0, 0, 0] |
| [0, 1, 0, 0, 0, 0, 0] | [1, 0, 0, 0, 0, 0, 0], [0, 0, 1, 0, 0, 0, 0], [0, 0, 0, 1, 0, 0, 0] |
| [0, 0, 1, 0, 0, 0, 0] | [1, 0, 0, 0, 0, 0, 0], [0, 1, 0, 0, 0, 0, 0], [0, 0, 0, 1, 0, 0, 0], [0, 0, 0, 0, 1, 0, 0] |
| [0, 0, 0, 1, 0, 0, 0] | [0, 1, 0, 0, 0, 0, 0], [0, 0, 1, 0, 0, 0, 0], [0, 0, 0, 0, 1, 0, 0], [0, 0, 0, 0, 0, 1, 0] |
| [0, 0, 0, 0, 1, 0, 0] | [0, 0, 1, 0, 0, 0, 0], [0, 0, 0, 1, 0, 0, 0], [0, 0, 0, 0, 0, 1, 0], [0, 0, 0, 0, 0, 0, 1] |
| [0, 0, 0, 0, 0, 1, 0] | [0, 0, 0, 1, 0, 0, 0], [0, 0, 0, 0, 1, 0, 0], [0, 0, 0, 0, 0, 0, 1] |
| [0, 0, 0, 0, 0, 0, 1] | [0, 0, 0, 0, 1, 0, 0], [0, 0, 0, 0, 0, 1, 0] |

옆의 예는 윈도우(window) 크기가 2 인 경우

슬라이딩 윈도우(sliding window): 윈도우 크기가 정해지면 윈도우를 옆으로 움직여서 주변 단어와 중심 단어의 선택을 변경해가며 학습을 위한 데이터 셋을 만듦

# 워드투벡터(Word2Vec)

## CBOW(Continuous Bag of Words)

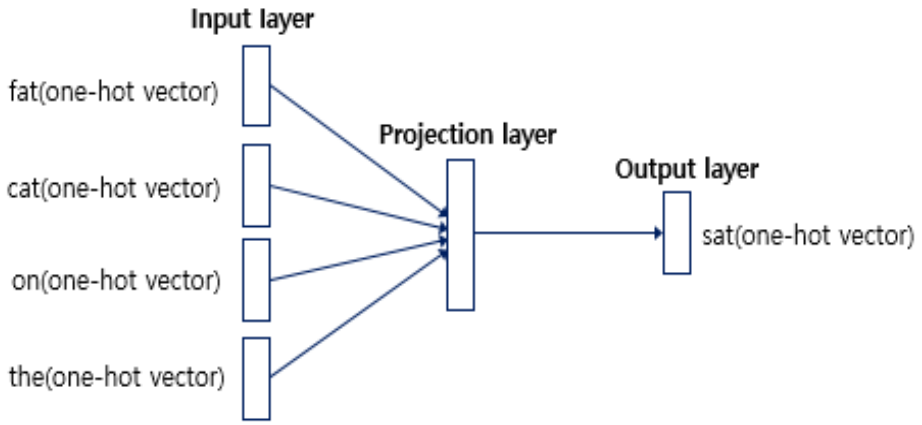


**입력층(Input layer)**의 입력으로서 앞, 뒤로 사용자가 정한 윈도우 크기 범위 안에 있는 **주변 단어들의 원-핫 벡터**가 들어감

**출력층(Output layer)**에서 예측하고자 하는 **중간 단어의 원-핫 벡터**가 **레이블**로서 필요

Word2Vec은 은닉층이 다수인 딥러닝 모델이 아니라 은닉층이 1개인 'shallow neural network'

Word2Vec의 은닉층은 활성화 함수가 존재하지 않으며, 룩업 테이블이라는 연산은 담당, **투사층(projection layer)**이라고 부름

# 워드투벡터(Word2Vec)

## CBOW(Continuous Bag of Words)

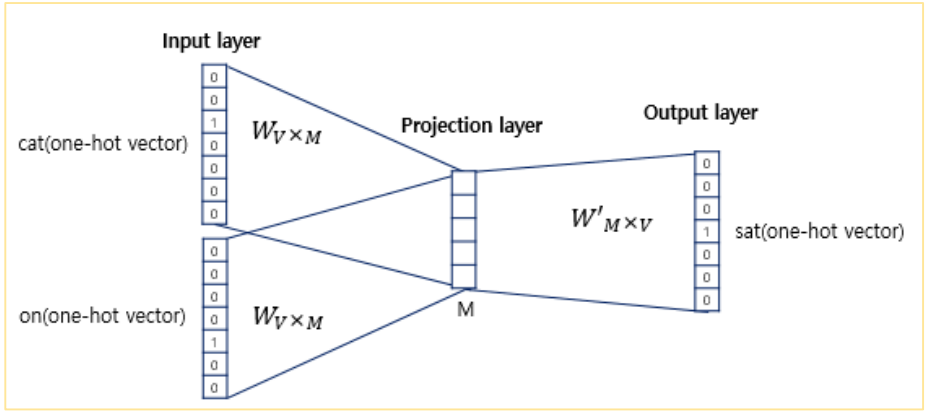


CBOW에서 투사층의 크기(M)는 임베딩하고 난 벡터의 차원이 됨.
- 그림에서 M=5, CBOW를 수행하고나서 얻는 각 단어의 임베딩 벡터의 차원은 5가 됨.

입력층과 투사층 사이의 가중치(W)는 V × M 행렬이며, 투사층에서 출력층 사이의 가중치(W′)는 M × V 행렬임(여기서 V는 단어 집합 크기)
- 그림에서 V=7, W는 7 × 5 행렬, W'는 5 × 7 행렬

인공 신경망 훈련 전에 가중치 행렬 W와 W'는 랜덤 값
- CBOW는 주변 단어로 중심 단어를 더 정확히 맞추기 위해 계속해서 이 **W와 W'를 학습해가는 구조**

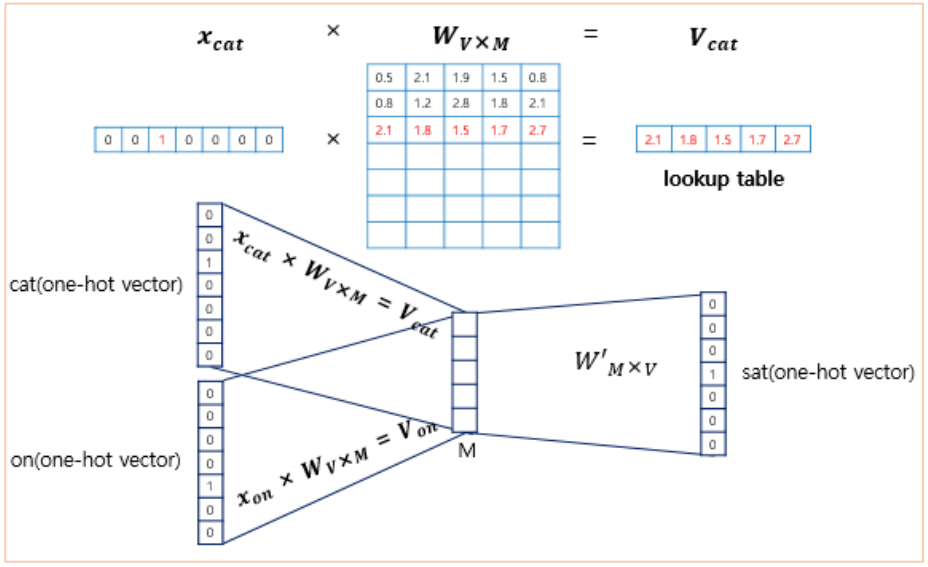


입력 벡터 x와 가중치 W 행렬의 곱은 사실 W행렬의 i번째 행을 그대로 읽어오는 것과(lookup) 동일

**lookup**해온 W의 각 행벡터가 Word2Vec 학습 후에는 각 단어의 M차원의 **임베딩 벡터**로 간주됨 = V_i (단어집합 크기 V와 다름!)

# 워드투벡터(Word2Vec)

## CBOW(Continuous Bag of Words)

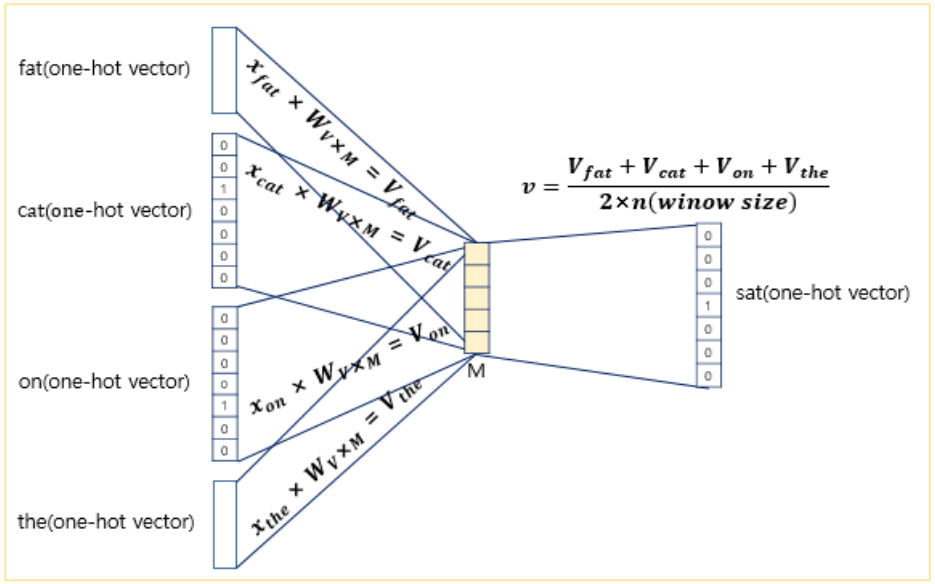


주변 단어의 원-핫 벡터(x)에 대해 가중치 W가 곱해서 생겨진 '결과 벡터들'(V_i)은 투사층에서 만나 **평균인 벡터**를 구하게 됨.

투사층에서 벡터의 평균을 구하는 부분은 CBOW가 Skip-Gram과 다른 차이점이기도 함

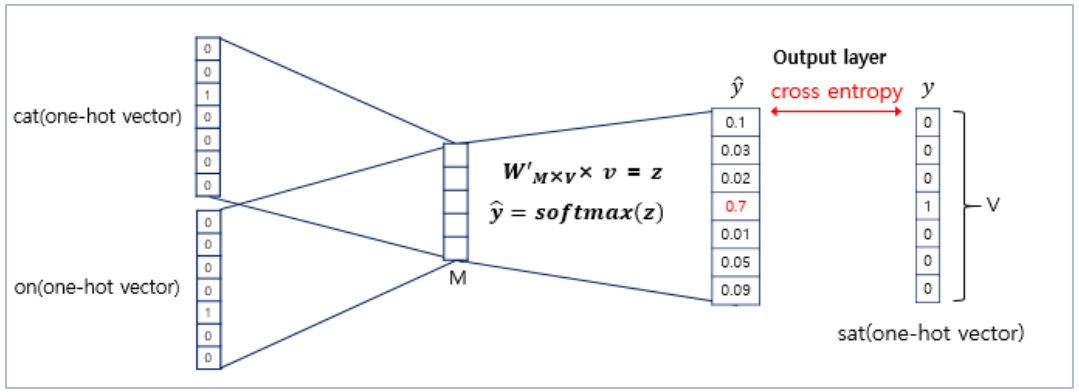


구해진 평균 벡터(v)는 두번째 가중치 행렬 W'와 곱해지며, 곱셈의 결과(z)로는 원-핫 벡터들과 차원이 V로 동일한 벡터가 나옴

이 벡터(z)에 CBOW는 **소프트맥스(softmax)** 함수를 지나고, 벡터의 각 원소들의 값은 **0과 1사이의 실수**를 가짐(총 합 1)

- 이는 다중 클래스 분류 문제를 위한 일종의 스코어 벡터(score vector)
- **스코어 벡터($\hat{y}$)**의 j번째 인덱스가 가진 값은 **j번째 단어가 중심 단어일 확률임**
- 이 스코어 벡터의 값은 **레이블(y)**에 해당하는 벡터인 중심 단어 원-핫 벡터의 값에 **가까워져야 함**

# 워드투벡터(Word2Vec)

## CBOW(Continuous Bag of Words)

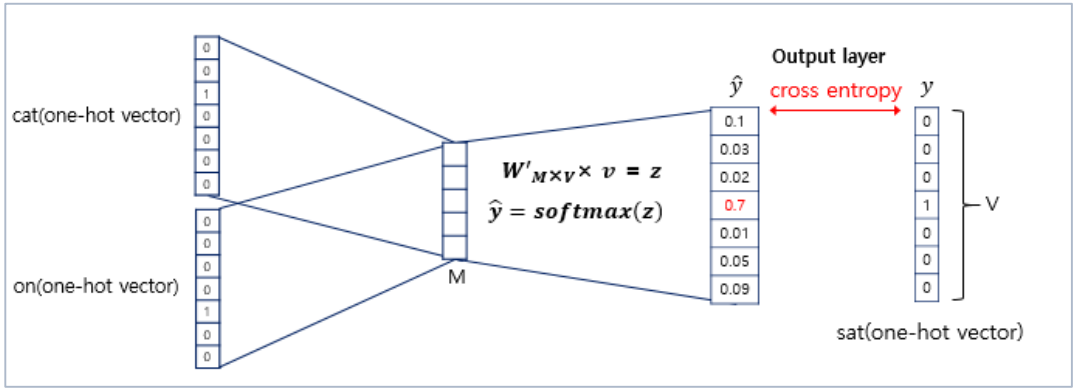


이 두 벡터값($\hat{y}$, y)의 오차를 줄이기위해 CBOW는 **손실 함수(loss function)로 크로스 엔트로피(cross-entropy) 함수** 사용

$$cost(\hat{y}, y) = -\sum_{j=1}^{V} y_j \, log(\hat{y}_j)$$

**역전파(Back Propagation)를 수행하면 W와 W'가 학습**됨

학습이 다 되었다면 M차원의 크기를 갖는 W의 행렬의 행을 각 단어의 임베딩 벡터로 사용하거나 W와 W' 행렬 두 가지 모두를 가지고 임베딩 벡터를 사용하기도 함.

# 워드투벡터(Word2Vec)

Skip-gram

- 중심에 있는 단어를 입력으로 주변에 있는 단어들을 예측하는 방법
- 나머지 방식은 CBOW와 동일

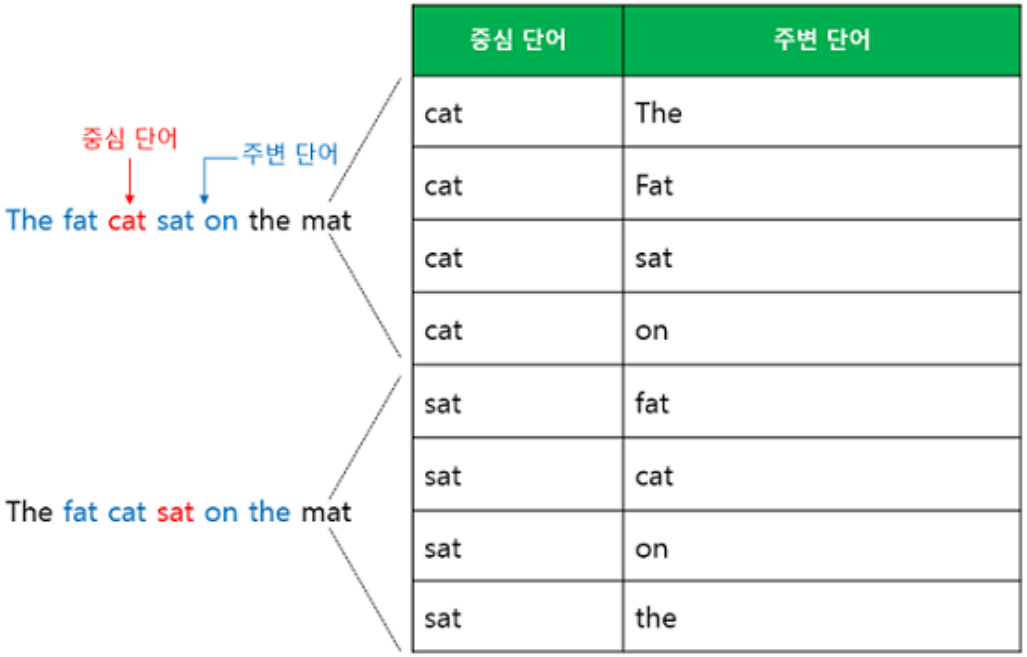


| 중심 단어 | 주변 단어 |
|---|---|
| cat | The |
| cat | Fat |
| cat | sat |
| cat | on |
| sat | fat |
| sat | cat |
| sat | on |
| sat | the |

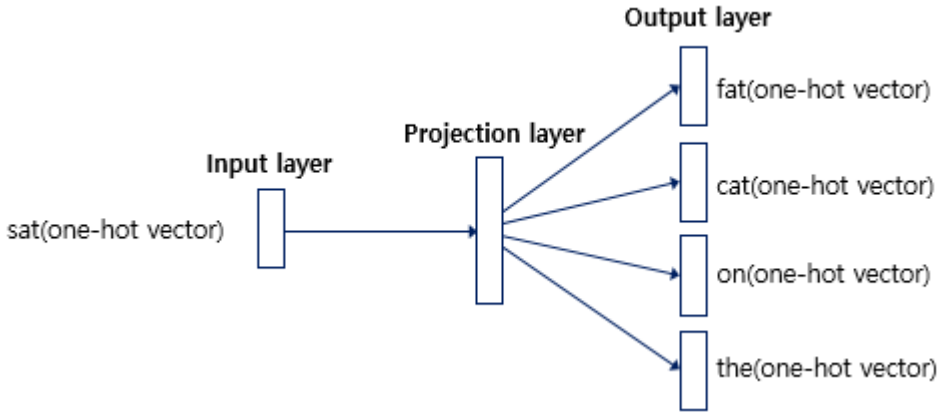

# 워드투벡터(Word2Vec)

## Skip-gram

보통 한 단어에 대해 여러 학습 기회를 가지는 Skip-gram의 성능이 더 좋다고 함

The fat cat sat on the table, window size=2

| CBOW | |
|---|---|
| Input | Output |
| Fat, cat | The |
| The, cat, sat | Fat |
| The, fat, sat, on | Cat |
| fat,cat,on,the | Sat |
| Cat,sat,the,table | On |
| Sat, on, table | The |
| On,the | table |

| the | fat | cat | sat | on | the | table |
|---|---|---|---|---|---|---|
| 1 | 1 | 1 | 1 | 1 | 1 | 1 |

| SKIP-GRAM | |
|---|---|
| Input | Output |
| The | Fat,cat |
| Fat | The,cat,sat |
| Cat | The,fat,sat,on |
| Sat | Fat,cat,on,the |
| On | Cat,sat,the,table |
| The | Sat,on,table |
| table | On,the |

| the | fat | cat | sat | on | the | table |
|---|---|---|---|---|---|---|
| 2 | 3 | 4 | 4 | 4 | 3 | 2 |

# 워드투벡터(Word2Vec)

만약 단어 집합의 크기가 수만 이상에 달한다면 Word2Vec은 학습하기에 무거운 모델이 됨.

- Word2Vec은 역전파 과정에서 **모든 단어의 임베딩 벡터값의 업데이트를 수행**

- 현재 집중하고 있는 중심 단어와 주변 단어가 ' 강아지 ' 와 ' 고양이 ', ' 귀여운 ' 과 같은 단어라면, 사실 이 단어들과 별 연관 관계가 없는 ' 돈가스 ' 나 ' 컴퓨터 ' 와 같은 수많은 단어의 임베딩 벡터값까지 업데이트하는 것은 **비효율적**임.

**네거티브 샘플링(negative sampling)**은 Word2Vec이 학습 과정에서 전체 단어 집합이 아니라 **일부 단어 집합에만 집중**할 수 있도록 하는 방법

- 하나의 중심 단어에 대해서 전체 단어 집합보다 훨씬 작은 단어 집합을 만들어 놓고 마지막 단계를 이진 분류 문제로 변환

- **주변 단어들을 긍정(positive)**, **랜덤으로 샘플링 된 단어들을 부정(negative)**으로 레이블링한다면 **이진 분류 문제**를 위한 데이터셋이 됨.

- 이는 기존의 단어 집합의 크기만큼의 선택지를 두고 다중 클래스 분류 문제를 풀던 Word2Vec보다 훨씬 연산량에서 효율적임.

# 워드투벡터(Word2Vec)

Skip-gram with negative sampling(SGNS)

- SGNS는 중심 단어와 주변 단어가 모두 입력이 되고, 두 단어가 실제 윈도우 크기 내에 존재하는 이웃 관계인지 그 확률을 예측


| 입력 | 레이블 |
|---|---|
| cat | The |
| cat | fat |
| cat | sat |
| cat | on |
| sat | fat |
| sat | cat |
| sat | on |
| sat | the |
| ... | ... |

| 입력1 | 입력2 | 레이블 |
|---|---|---|
| cat | The | 1 |
| cat | fat | 1 |
| cat | sat | 1 |
| cat | on | 1 |
| sat | fat | 1 |
| sat | cat | 1 |
| sat | on | 1 |
| sat | the | 1 |
| ... | ... | ... |

| 입력1 | 입력2 | 레이블 |
|---|---|---|
| cat | The | 1 |
| cat | fat | 1 |
| **cat** | **pizza** | **0** |
| **cat** | **computer** | **0** |
| cat | sat | 1 |
| cat | on | 1 |

# 워드투벡터(Word2Vec)

## Skip-gram with negative sampling(SGNS)

| 입력1 | 입력2 | 레이블 |
|---|---|---|
| cat | The | 1 |
| cat | fat | 1 |
| cat | pizza | 0 |
| cat | computer | 0 |
| cat | sat | 1 |
| cat | on | 1 |
| cat | cute | 1 |
| cat | mighty | 0 |
| ... | ... | ... |

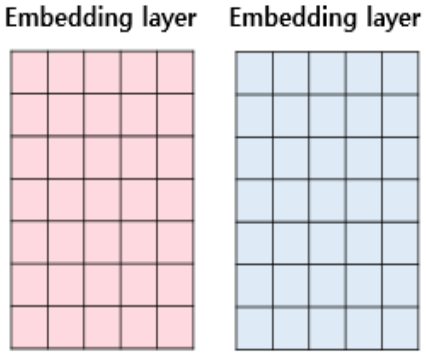


두 테이블 중
하나는 입력 1인 중심 단어의 테이블 룩업을 위한 임베딩 테이블,
하나는 입력 2인 주변 단어의 테이블 룩업을 위한 임베딩 테이블

각 단어는 각 임베딩 테이블을 테이블 룩업하여 임베딩 벡터로 변환

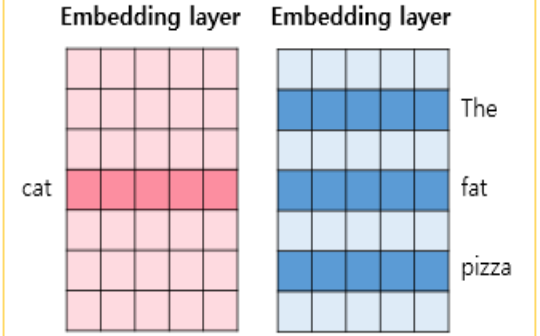


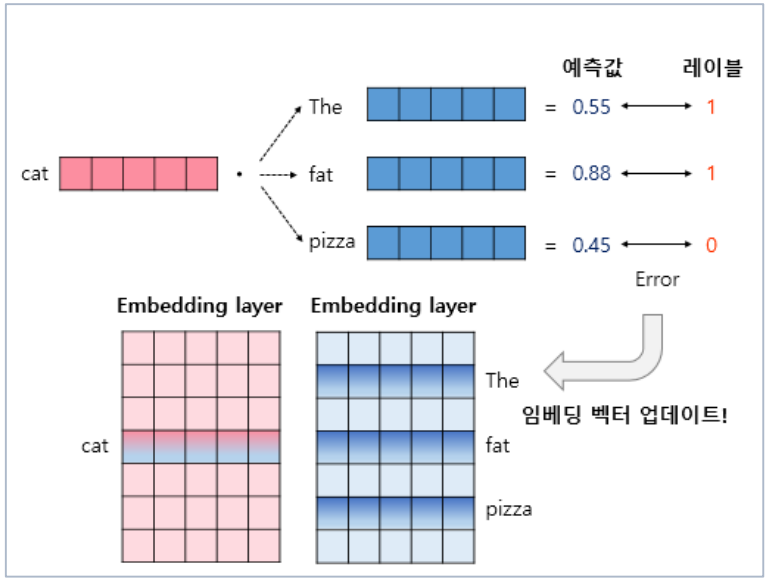


**중심 단어와 주변 단어의 내적값**을 이 모델의 **예측값**으로 하고,
**레이블과의 오차로부터 역전파**하여 중심 단어와 주변 단어의 **임베딩 벡터값을 업데이트**

# 워드투벡터(Word2Vec)

## Skip-gram with negative sampling(SGNS) - Keras 이용

```
from tensorflow.keras.preprocessing.sequence import skipgrams
```

```
skip_grams = [skipgrams(sample, vocabulary_size=vocab_size, window_size=10) for sample in encode
d]
```

```
embedding_dim = 100

# 중심 단어를 위한 임베딩 테이블
w_inputs = Input(shape=(1, ), dtype='int32')
word_embedding = Embedding(vocab_size, embedding_dim)(w_inputs)

# 주변 단어를 위한 임베딩 테이블
c_inputs = Input(shape=(1, ), dtype='int32')
context_embedding  = Embedding(vocab_size, embedding_dim)(c_inputs)
```

```
dot_product = Dot(axes=2)([word_embedding, context_embedding])
dot_product = Reshape((1,), input_shape=(1, 1))(dot_product)
output = Activation('sigmoid')(dot_product)

model = Model(inputs=[w_inputs, c_inputs], outputs=output)
model.summary()
model.compile(loss='binary_crossentropy', optimizer='adam')
```

```
for epoch in range(1, 6):
    loss = 0
    for _, elem in enumerate(skip_grams):
        first_elem = np.array(list(zip(*elem[0]))[0], dtype='int32')
        second_elem = np.array(list(zip(*elem[0]))[1], dtype='int32')
        labels = np.array(elem[1], dtype='int32')
        X = [first_elem, second_elem]
        Y = labels
        loss += model.train_on_batch(X,Y)
    print('Epoch :',epoch, 'Loss :',loss)
```

```
Epoch: 1 Loss: 4339.997158139944
Epoch: 2 Loss: 3549.69356325455
Epoch: 3 Loss: 3295.072506020777
Epoch: 4 Loss: 3038.1063768607564
Epoch: 5 Loss: 2790.9479411702487
```

# 글로브(GloVe)

글로브(Global Vectors for Word Representation) (2014, Stanford)

: 카운트 기반, 예측기반을 모두 사용하는 방법론

**카운트 기반**

- LSA(Latent Semantic Analysis): DTM이나 TF-IDF 행렬과 같이 각 문서에서의 각 단어의 빈도수를 카운트 한 행렬이라는 전체적인 통계 정보를 입력으로 받아 차원을 축소(Truncated SVD)하여 잠재된 의미를 끌어내는 방법론
- 단어 의미의 유추 작업(Analogy task)에 성능이 떨어짐

**예측 기반**

- Word2Vec: 실제값과 예측값에 대한 오차를 손실 함수를 통해 줄여나가며 학습
- 임베딩 벡터가 윈도우 크기 내에서만 주변 단어를 고려하기 때문에 코퍼스의 전체적인 통계 정보를 반영하지 못함

# 글로브(GloVe)

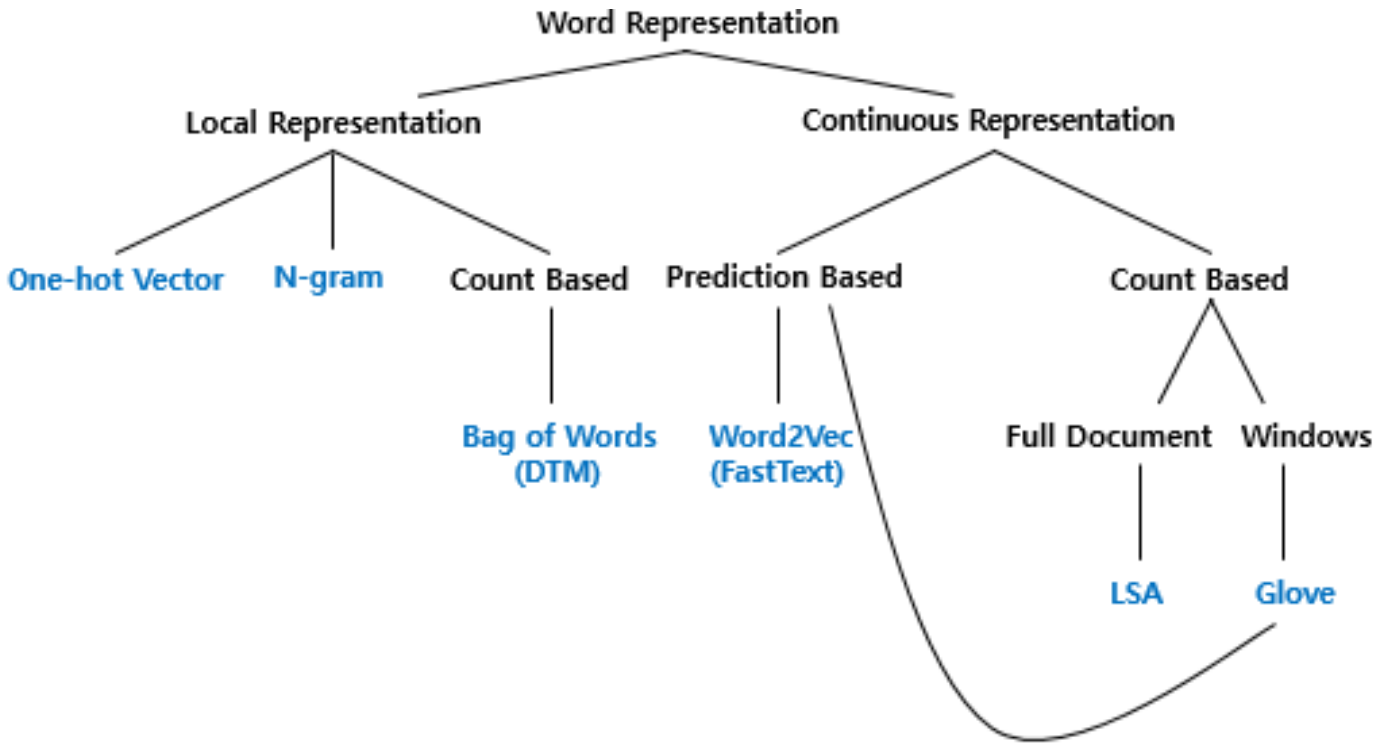
Word Representation
Local Representation
Continuous Representation
One-hot Vector
N-gram
Count Based
Prediction Based
Count Based
Bag of Words
(DTM)
Word2Vec
(FastText)
Full Document
Windows
LSA
Glove

# 글로브(GloVe)

**윈도우 기반 동시 등장 행렬(window based co-occurrence matrix)**

- I like deep learning
- I like NLP
- I enjoy flying

| 카운트 | I | like | enjoy | deep | learning | NLP | flying |
|---|---|---|---|---|---|---|---|
| I | 0 | 2 | 1 | 0 | 0 | 0 | 0 |
| like | 2 | 0 | 0 | 1 | 0 | 1 | 0 |
| enjoy | 1 | 0 | 0 | 0 | 0 | 0 | 1 |
| deep | 0 | 1 | 0 | 0 | 1 | 0 | 0 |
| learning | 0 | 0 | 0 | 1 | 0 | 0 | 0 |
| NLP | 0 | 1 | 0 | 0 | 0 | 0 | 0 |
| flying | 0 | 0 | 1 | 0 | 0 | 0 | 0 |

# 글로브(GloVe)

**동시 등장 확률(co-occurrence probability)**

| 동시 등장 확률과 크기 관계 비(ratio) | k=solid | k=gas | k=water | k=fasion |
|---|---|---|---|---|
| P(k l ice) | 0.00019 | 0.000066 | 0.003 | 0.000017 |
| P(k l steam) | 0.000022 | 0.00078 | 0.0022 | 0.000018 |
| P(k l ice) / P(k l steam) | 8.9 | 0.085 | 1.36 | 0.96 |

GloVe의 아이디어를 한 줄로 요약하면 **'임베딩 된 중심 단어와 주변 단어 벡터의 내적이 전체 코퍼스에서의 동시 등장 확률(의 로그값)이 되도록 만드는 것'**

$$dot\ product(w_i\ \tilde{w}_k) \approx\ log\ P(k \mid i) = log\ P_{ik}$$

→ 손실 함수 설계

- $X$ : 동시 등장 행렬(Co-occurrence Matrix)
- $X_{ij}$ : 중심 단어 i가 등장했을 때 윈도우 내 주변 단어 j가 등장하는 횟수
- $X_i : \sum_j X_{ij}$ : 동시 등장 행렬에서 i행의 값을 모두 더한 값
- $P_{ik} : P(k \mid i) = \frac{X_{ik}}{X_i}$ : 중심 단어 i가 등장했을 때 윈도우 내 주변 단어 k가 등장할 확률
  Ex) P(solid l ice) = 단어 ice가 등장했을 때 단어 solid가 등장할 확률
- $\frac{P_{ik}}{P_{jk}}$ : $P_{ik}$를 $P_{jk}$로 나눠준 값
  Ex) P(solid l ice) / P(solid l steam) = 8.9
- $w_i$ : 중심 단어 i의 임베딩 벡터
- $\tilde{w}_k$ : 주변 단어 k의 임베딩 벡터

# 글로브(GloVe)

**손실함수**

$$F(w_i,\ w_j,\ \tilde{w}_k) = \frac{P_{ik}}{P_{jk}}$$

두 개의 중심단어가 주어지고 하나의 주변단어가 주어질 때 어떠한 함수 F를 통해 동시 발생 확률 비율을 도출

$$F(w_i - w_j,\ \tilde{w}_k) = \frac{P_{ik}}{P_{jk}}$$

$$F((w_i - w_j)^T \tilde{w}_k) = \frac{P_{ik}}{P_{jk}}$$

벡터 간 관계를 따져보기 위해 w_i와 w_j를 뺀 벡터에 w_k를 내적함.
(빼는 이유는 추후 준동형(Homomorphism)이 성립 되어 손쉽게 처리할 수 있기 때문)

$$F(a+b) = F(a)F(b),\ \forall a,\ b \in \mathbb{R}$$

준동형(Homomorphism)식 (F는 준동형 식이라는 필수 조건 설정)

$$F(v_1^T v_2 + v_3^T v_4) = F(v_1^T v_2)F(v_3^T v_4),\ \forall v_1,\ v_2,\ v_3,\ v_4 \in V$$

준동형(Homomorphism)식 – 벡터 값

$$F(v_1^T v_2 - v_3^T v_4) = \frac{F(v_1^T v_2)}{F(v_3^T v_4)},\ \forall v_1,\ v_2,\ v_3,\ v_4 \in V$$

준동형(Homomorphism)식 – 벡터 값 뺄셈

$$F((w_i - w_j)^T \tilde{w}_k) = \frac{F(w_i^T \tilde{w}_k)}{F(w_j^T \tilde{w}_k)}$$

준동형(Homomorphism)식을 GloVe식에 적용

# 글로브(GloVe)

**손실함수**

$$\frac{P_{ik}}{P_{jk}} = \frac{F(w_i^T \tilde{w}_k)}{F(w_j^T \tilde{w}_k)}$$

이전 식을 좌변에 대입

$$F(w_i^T \tilde{w}_k - w_j^T \tilde{w}_k) = \frac{F(w_i^T \tilde{w}_k)}{F(w_j^T \tilde{w}_k)}$$

좌변을 풀어 쓰면, 뺄셈에 대한 준동형식과 일치

$$exp(w_i^T \tilde{w}_k - w_j^T \tilde{w}_k) = \frac{exp(w_i^T \tilde{w}_k)}{exp(w_j^T \tilde{w}_k)}$$

이러한 식을 만족하는 함수로 지수 함수(exponential function)이 있음!

$$exp(w_i^T \tilde{w}_k) = P_{ik} = \frac{X_{ik}}{X_i}$$

다음 식 도출 가능

$$w_i^T \tilde{w}_k = log\, P_{ik} = log\, (\frac{X_{ik}}{X_i}) = log\, X_{ik} - log\, X_i$$

$$w_i^T \tilde{w}_k + b_i + \tilde{b_k} = log\, X_{ik}$$

log X_i를 b_i와 b_k라는 편향 상수항으로 대체

좌변과 우변의 차를 손실 함수로 정의

# 글로브(GloVe)

**손실함수**

$$Loss\ function = \sum_{m,n=1}^{V} (w_m^T \tilde{w}_n + b_m + \tilde{b_n} - logX_{mn})^2$$

단, X_ik 가 0이 될 수 있음 → 가중치 함수 f(Xi_ij)를 도입

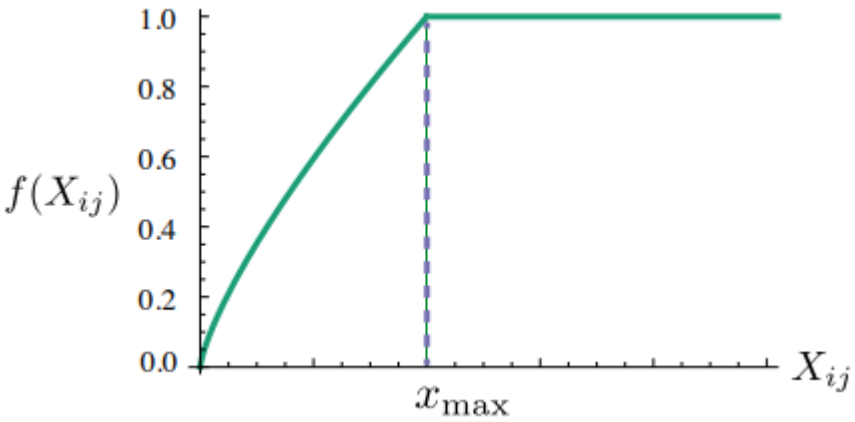


$$f(x) = min(1,\ (x/x_{max})^{3/4})$$

$$Loss\ function = \sum_{m,n=1}^{V} f(X_{mn})(w_m^T \tilde{w}_n + b_m + \tilde{b_n} - logX_{mn})^2$$

최종적인 일반화된 손실 함수

# 글로브(GloVe)

```
from glove import Corpus, Glove

corpus = Corpus()

# 훈련 데이터로부터 GloVe에서 사용할 동시 등장 행렬 생성
corpus.fit(result, window=5)
glove = Glove(no_components=100, learning_rate=0.05)

# 학습에 이용할 쓰레드의 개수는 4로 설정, 에포크는 20.
glove.fit(corpus.matrix, epochs=20, no_threads=4, verbose=True)
glove.add_dictionary(corpus.dictionary)
```

# 패스트텍스트(FastText)

패스트텍스트(FastText) (2015, facebook)

Word2Vec의 확장, 단 **하나의 단어에도 여러 단어들이 존재**하는 것으로 간주. 즉, **서브워드(subword)**를 고려하여 학습

**서브워드(subword)**

- 각 단어를 글자 단위 n-gram의 구성을 취급
- 단 시작과 끝인 <, >, 그리고 기존 단어 토큰 <word>를 추가

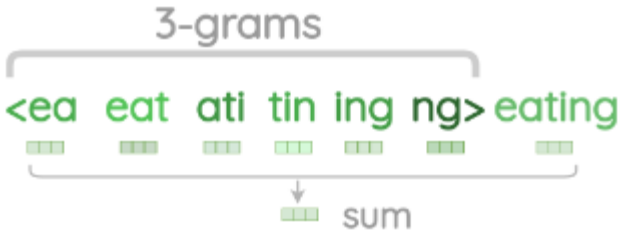


- 기본 값으로 최소=3, 최대=6으로 설정 되어 있음.
- 이 때, 서브워드를 벡터화하고,
- 단어(ex. apple)의 벡터값은 벡터값들의 총 합으로 구성함


```
# n = 3 ~ 6인 경우
<ap, app, ppl, ppl, le>, <app, appl, pple, ple>, <appl, pple>, ..., <apple>
```

```
apple = <ap + app + ppl + ppl + le> + <app + appl + pple + ple> + <appl + pple> + , ..., +<apple>
```

# 패스트텍스트(FastText)

## **모르는 단어(out of vocabulary, OOV)**에 대한 대응

- FastText의 인공 신경망을 학습한 후에는 데이터 셋의 모든 단어의 각 n-gram에 대해서 워드 임베딩이 됨.
- subword를 통해 모르는 단어(OOV)에 대해서도 다른 단어와의 유사도를 계산할 수 있음.
- Ex. ‘birthplace’는 학습되지 않고, ‘birth’와 ‘place’는 되었다면, FastText는 ‘birthplace’ 벡터를 얻을 수 있음.

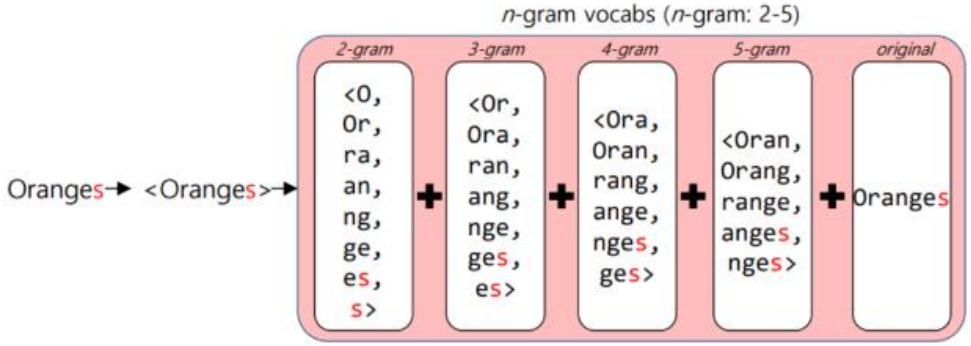


```
KeyError: "word 'electrofishing' not in vocabulary"
```

**Word2Vec**

```
model.wv.most_similar("electrofishing")
```

**FastText**

```
[('electrolux', 0.7934642434120178), ('electrolyte', 0.78279709815979), ('electro', 0.77912783622
7417), ('electric', 0.7753111720085144), ('airbus', 0.7648627758026123), ('fukushima', 0.76124227
04696655), ('electrochemical', 0.7611693143844604), ('gastric', 0.7483425140380859), ('electrosho
ck', 0.7477173805236816), ('overfishing', 0.7435552477836609)]
```

# 패스트텍스트(FastText)

**빈도 수가 적었던 단어(rare word)**에 대한 대응

- Word2Vec은 등장 빈도가 적은 단어에 대해 임베딩 정확도가 낮음.
- 하지만 FastText는 그 단어의 n-gram이 다른 단어의 n-gram과 겹치면 정확도 상승
- 또한 노이즈(오타 등)가 많은 코퍼스에서 강점을 가짐. (ex. oranze)

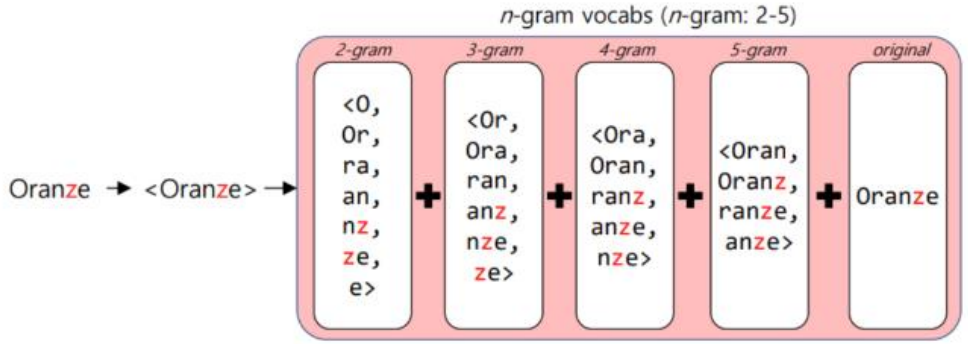

# 패스트텍스트(FastText)

## 한국어 FastText

### 음절 단위

'자연어처리' n=3

```
<자연, 자연어, 연어처, 어처리, 처리>
```

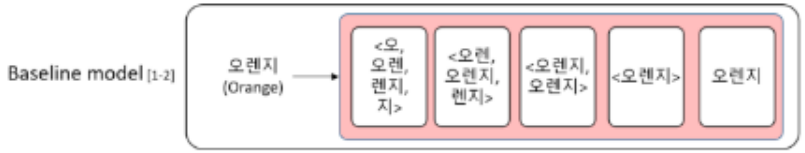


### 자모 단위

- 자모 단위로 가게 되면 오타나 노이즈 측면에서 더 강한 임베딩을 기대
- 한국어의 오탈자는 초/중/종성에서 한군데 정도가 틀리기 때문에 자음/모음을 풀어서 FastText를 학습하는게 좋음
- 파이썬 *hgtk* 패키지 사용

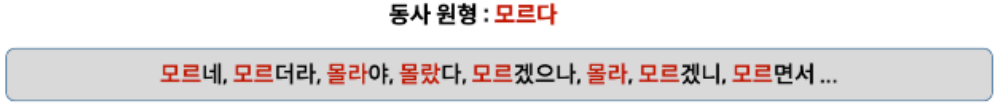


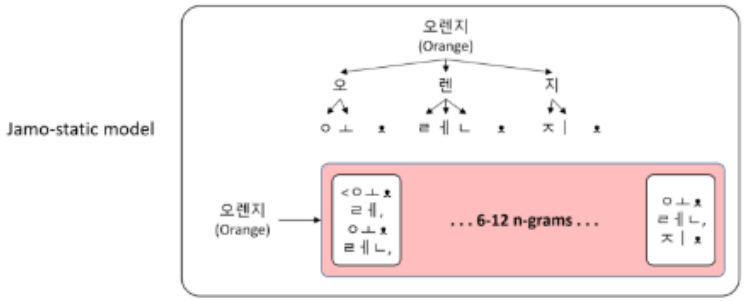

# 엘모(ELMo)

**ELMo(Embeddings from Language Model)**

- 문맥을 반영한 워드 임베딩(Contextualized Word Embedding)
- Ex. Bank는 Bank Account(은행 계좌)와 River Bank(강둑)에서 전혀 다른 의미를 가짐. 이 때 Word2Vec이나 GloVe 등으로 표현된 임베딩 벡터들은 이를 제대로 반영하지 못함.

biLM(Bidirectional Language Model)

- ELMo는 순방향 RNN 뿐만 아니라, 위의 그림과는 반대 방향으로 문장을 스캔하는 역방향 RNN 또한 활용. 즉, ELMo는 양쪽 방향의 언어 모델을 둘 다 학습하여 활용

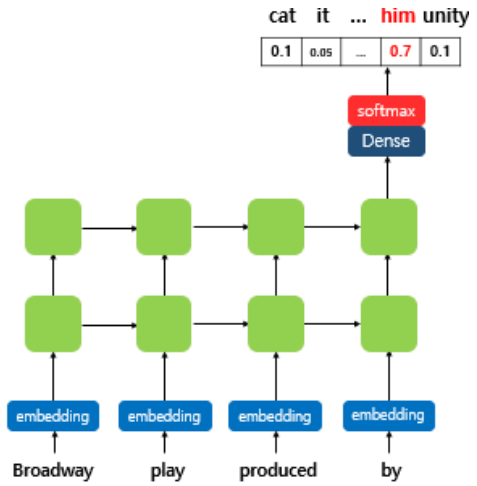


순방향 RNN

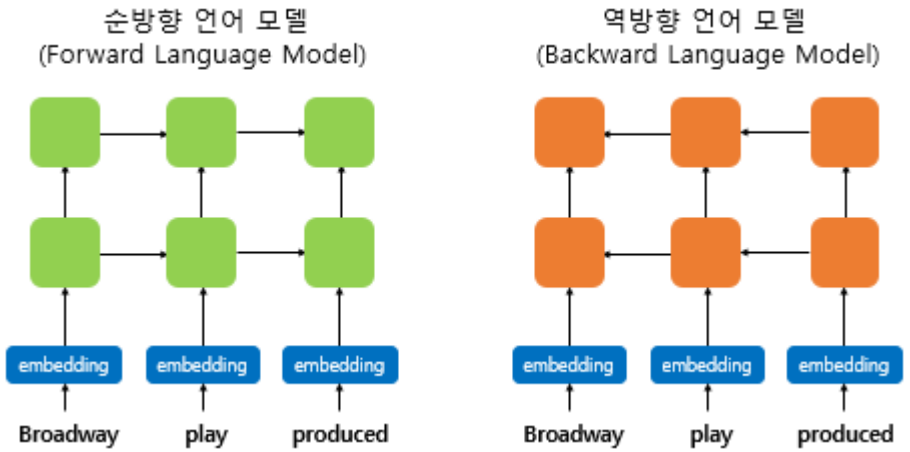


biLM, 다층 구조(Multi-layer)(은닉층이 최소 2개 이상)를 전제로 함

# 엘모(ELMo)

biLM(Bidirectional Language Model)

- biLM의 각 시점의 입력이 되는 단어 벡터는 **합성곱 신경망**을 이용한 **문자 임베딩(character embedding)**을 통해 얻은 단어 벡터임.
  - 문자 임베딩은 마치 서브단어(subword)의 정보를 참고하는 것처럼 문맥과 상관없이 dog란 단어와 doggy란 단어의 연관성을 찾아낼 수 있음.
- 양방향 RNN vs. ELMo의 biLM
  - 양방향 RNN은 순방향 RNN의 은닉 상태와 역방향의 RNN의 은닉 상태를 연결(concatenate)하여 다음층의 입력으로 사용
  - 반면, **biLM의 순방향 언어모델과 역방향 언어모델이라는 두 개의 언어 모델을 별개의 모델로 보고 학습**

# 엘모(ELMo)

## biLM의 활용

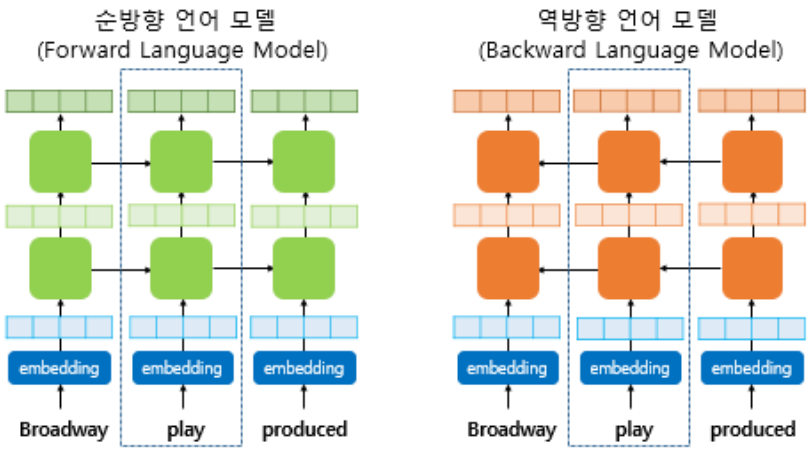


play라는 단어를 임베딩 하기 위해 점선 사각형 내부의 각 층의 결과값을 재료로 사용
즉, 해당 시점(time step)의 BiLM의 각 층의 출력값을 가져옴

그리고 **순방향 언어 모델과 역방향 언어 모델의 각 층의 출력값을 연**결
여기서 각 층의 출력값이란 첫번째는 임베딩 층을 말하며, 나머지 층은 각 층의 은닉 상태를 말함.

ELMo의 직관적인 아이디어는 **각 층의 출력값이 가진 정보는 전부 서로 다른 종류의 정보**를 갖고 있을 것이므로, 이들을 모두 활용한다는 점

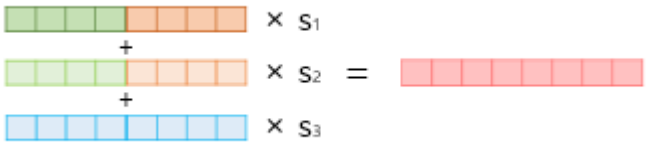



1) 각 층의 출력값을 연결(concatenate)
2) 각 층의 출력값 별로 가중치를 줌
3) 각 층의 출력값을 모두 더함

4) 벡터의 크기를 결정하는 스칼라 매개변수를 곱함
→ 완성된 벡터를 **ELMo 표현(representation)**이라고 함

이 ELMo표현을 입력으로 사용하여 수행하고 싶은 텍스트 분류, 질의 응답 시스템 등의 자연어 처리 작업

# 엘모(ELMo)

## ELMo 표현의 사용

ELMo 표현은 기존의 임베딩 벡터와 함께 사용할 수 있음.

우선 텍스트 분류 작업을 위해서 GloVe와 같은 **기존의 방법론을 사용한 임베딩 벡터**를 준비 + **준비된 ELMo 표현**을 GloVe 임베딩 벡터와 **연결(concatenate)**해서 입력으로 사용

이때 biLM의 가중치는 고정시키고, 위에서 사용한 s_1, s_2, s_3 와 $\gamma$는 훈련 과정에서 학습됨.

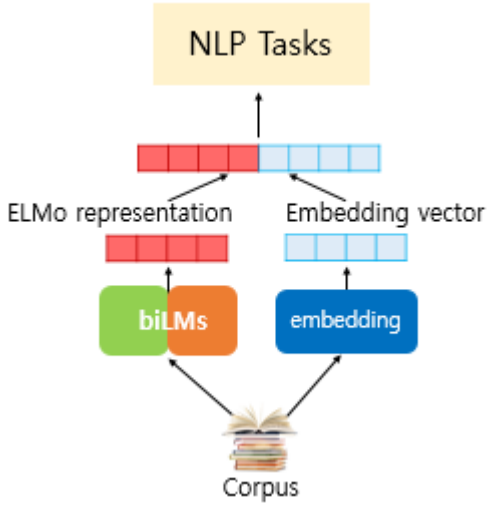


```
elmo = hub.Module("https://tfhub.dev/google/elmo/1", trainable=True)
# 텐서플로우 허브로부터 ELMo를 다운로드
```

```
def ELMoEmbedding(x):
    return elmo(tf.squeeze(tf.cast(x, tf.string)), as_dict=True, signature="default")["default"]
# 데이터의 이동이 케라스 → 텐서플로우 → 케라스가 되도록 하는 함수
```

```
input_text = Input(shape=(1,), dtype=tf.string)
embedding_layer = Lambda(ELMoEmbedding, output_shape=(1024, ))(input_text)
hidden_layer = Dense(256, activation='relu')(embedding_layer)
output_layer = Dense(1, activation='sigmoid')(hidden_layer)
model = Model(inputs=[input_text], outputs=output_layer)
model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
```

# 참고자료


- 딥 러닝을 이용한 자연어 처리 입문(https://wikidocs.net/book/2155)
- 자모 단위의 한국어 FastText 이해와 실습 (https://museonghwang.github.io/nlp(natural%20language%20processing)/2023/02/10/nlp-kor-fasttext/)